Сборный проект - 1

Описание проекта

Цель проекта

Цель проекта - проанализировать данные о международных продажах видеоигр для того, чтобы спланировать рекламную кампанию на следующий год.

Необходимо:

- провести исследовательский анализ данных
- составить портер пользователя из каждого региона
- проверить гипотезы о рейтингах игр для различных платформ и рейтингах игр разных жанров

Исходные данные

In [1]:
```python
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.colors as mcolors
import seaborn as sns
import plotly.graph_objs as go
from plotly.subplots import make_subplots
from mpl_toolkits.axes_grid1 import make_axes_locatable
from mpl_toolkits.axes_grid1.axes_divider import make_axes_area_auto_adjustable
from scipy import stats as st
```

In [2]:
```python
data = pd.read_csv('/datasets/games.csv')
```

In [3]:
```python
data.head()
```

Out[3]:

	Name	Platform	Year_of_Release	Genre	NA_sales	EU_sales	JP_sales	Other_sales	Critic_Score	User_Score	Rating
0	Wii Sports	Wii	2006.0	Sports	41.36	28.96	3.77	8.45	76.0	8	E
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77	NaN	NaN	NaN
2	Mario Kart Wii	Wii	2008.0	Racing	15.68	12.76	3.79	3.29	82.0	8.3	E
3	Wii Sports Resort	Wii	2009.0	Sports	15.61	10.93	3.28	2.95	80.0	8	E
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN

В исходных данных предоставлена информация о видео-играх, продающихся в интернет магазине "Стримчик". Для каждой видеоигры указаны:

- название видеоигры;
- платформа;
- год выпуска;
- жанр;
- продажи для разных регионов (в млн проданных копий):
  - NA - *Северная Америка*
  - EU - *Европа*
  - JP - *Япония*
  - Other - *остальные страны*
- оценка игры:
  - оценка критиков
  - оценка пользователей
- возрастной рейтинг ESRB

План работы

Для успешного выполнения проекта и анализа имеющихся данных необходимо:

1. Предобработать данные:
   - [x] привести названия столбцов к одному регистру
   - [x] обработать имеющиеся пропуски (*заменить отсутствующие значения, либо удалить строки с пропусками при необходимости*)
   - [x] при необходимости изменить тип данных
   - [x] удалить дубликаты (явные и неявные)
   - [x] подсчитать суммарные продажи во всех регионах
2. Провести исследовательский анализ данных:
   - [x] изучить сколько игр выпускалось в разные годы
   - [x] изучить изменение продаж по платформам
   - [x] выбрать актуальный период для дальнейшего прогноза на 2017 год
   - [x] проанализировать различные платформы
   - [x] изучить глобальные продажи видеоигр
   - [x] изучить влияние отзывов критиков и пользователей на продажи видеоигры внутри платформ
   - [x] проанализировать жанры видеоигр и их влияние на продажи
3. Составить портер пользователя каждого региона, определить:
   - [x] самые популярные платформы (топ-5)
   - [x] самые популярные жанры (топ-5)
   - [x] влияние рейтинга ESRB на продажи в регионе
4. Проверить гипотезы:
   - [x] средние пользовательские рейтинги платформ Xbox One и PC одинаковые
   - [x] средние пользовательские рейтинги жанров Action и Sports разные
5. Сделать общий вывод

Общая информация о данных

In [4]:
```python
print(data.info())
data.head(10)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16715 entries, 0 to 16714
Data columns (total 11 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   Name             16713 non-null  object
 1   Platform         16715 non-null  object
 2   Year_of_Release  16446 non-null  float64
 3   Genre            16713 non-null  object
 4   NA_sales         16715 non-null  float64
 5   EU_sales         16715 non-null  float64
 6   JP_sales         16715 non-null  float64
 7   Other_sales      16715 non-null  float64
 8   Critic_Score     8137 non-null   float64
 9   User_Score       10014 non-null  object
 10  Rating           9949 non-null   object
dtypes: float64(6), object(5)
memory usage: 1.4+ MB
None
```

Out[4]:

	Name	Platform	Year_of_Release	Genre	NA_sales	EU_sales	JP_sales	Other_sales	Critic_Score	User_Score	Rating
0	Wii Sports	Wii	2006.0	Sports	41.36	28.96	3.77	8.45	76.0	8	E
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77	NaN	NaN	NaN
2	Mario Kart Wii	Wii	2008.0	Racing	15.68	12.76	3.79	3.29	82.0	8.3	E
3	Wii Sports Resort	Wii	2009.0	Sports	15.61	10.93	3.28	2.95	80.0	8	E
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN
5	Tetris	GB	1989.0	Puzzle	23.20	2.26	4.22	0.58	NaN	NaN	NaN
6	New Super Mario Bros.	DS	2006.0	Platform	11.28	9.14	6.50	2.88	89.0	8.5	E
7	Wii Play	Wii	2006.0	Misc	13.96	9.18	2.93	2.84	58.0	6.6	E
8	New Super Mario Bros. Wii	Wii	2009.0	Platform	14.44	6.94	4.70	2.24	87.0	8.4	E
9	Duck Hunt	NES	1984.0	Shooter	26.93	0.63	0.28	0.47	NaN	NaN	NaN

In [5]:
```python
print(data['Year_of_Release'].min(), data['Year_of_Release'].max())
```

```
1980.0 2016.0
```

Как было написано в описании проекта, данные представляют собой общую информацию о видеоиграх. Имеется информация о **платформе**, **годе выпуска**, **жанре**, **продажах**, **оценках критиков и пользователей** и **возрастном рейтинге**.

В таблице **16715** строк. Имеется информация об играх с 1980 по 2016 год.

Предобработка данных

Изменение названия столбцов

Для облегчения дальнейшего анализа данных, необходимо привести все названия столбцов к формату *snake_case*.

In [6]:
```python
data.columns = data.columns.str.lower()
data.columns
```

Out[6]:
```
Index(['name', 'platform', 'year_of_release', 'genre', 'na_sales', 'eu_sales',
       'jp_sales', 'other_sales', 'critic_score', 'user_score', 'rating'],
      dtype='object')
```

Удаление дубликатов

In [7]:
```python
data.duplicated().sum()
```

Out[7]:
```
0
```

Явные дубликаты отсутствуют. Попробуем найти неявные дубликаты, в нашем случае, необходимо провести проверку на наличие строк с одновременно одинаковыми именем, платформой и годом релиза, поскольку иначе это может быть ремейк/перевыпуск.

In [8]:
```python
data.duplicated(subset=['name', 'platform', 'year_of_release'], keep=False).sum()
```

Out[8]:
```
4
```

Таких строк 4. Рассмотрим их.

In [9]:
```python
data.loc[data.duplicated(subset=['name', 'platform', 'year_of_release'], keep=False)].sort_values(by='name')
```

Out[9]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating
604	Madden NFL 13	PS3	2012.0	Sports	2.11	0.22	0.00	0.23	83.0	5.5	E
16230	Madden NFL 13	PS3	2012.0	Sports	0.00	0.01	0.00	0.00	83.0	5.5	E
659	NaN	GEN	1993.0	NaN	1.78	0.53	0.00	0.08	NaN	NaN	NaN
14244	NaN	GEN	1993.0	NaN	0.00	0.00	0.03	0.00	NaN	NaN	NaN

В обоих случаях видно, что строка полностью совпадает, кроме данных о продажах. В первом случае необходимо оставить только строку, в которой есть полная информация о продажах. Во втором случае, можно удалить обе строки, поскольку в них много пропусков, год выпуска - 1993, т.е. нерелевантен, а платформа (GEN) уже не поддерживается, это будет сделано в дальнейшем при обработке пропусков.

In [10]:
```python
data.drop_duplicates(
    subset=['name', 'platform', 'year_of_release'],
    keep='first',
    inplace=True
)
```

Расчет общих продаж

Добавим столбец с расчетом общих продаж по всем регионам. Это позволит нам, помимо далльнейшего анализа, добавить еще один инструмент категоризации данных при заполнении пропусков.

In [11]:
```python
data['total_sales'] = data.loc[:,['na_sales','eu_sales', 'jp_sales', 'other_sales']].sum(axis=1)
```

Обработка пропусков

Подсчитаем количество пропусков в данных

In [12]:
```python
data.isna().sum()
```

Out[12]:
```
name                  1
platform              0
year_of_release     269
genre                 1
na_sales              0
eu_sales              0
jp_sales              0
other_sales           0
critic_score       8577
user_score         6700
rating             6765
total_sales           0
dtype: int64
```

В **6** столбцах присутствуют пропуски. Больше всего пропусков в столбце с оценками критиков (**8578**), чуть меньше пропусков в столбцах с оценками пользователей и возрастным рейтингом (**~6700**). По **1** пропуску в информации о названии видеоигры и жанра. Год выпуска не указан для **269** строк.

Название видеоигры и жанр

Рассмотрим столбец с жанрами. По имени игры мы сможем определить, как заполнить пропущенные значения.

In [13]:
```python
data.query('genre.isna()')
```

Out[13]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
659	NaN	GEN	1993.0	NaN	1.78	0.53	0.0	0.08	NaN	NaN	NaN	2.39

В данной строке отсутствуют все данные, кроме года выпуска и продаж. Следовательно, мы не сможем заполнить эти пропуски. Кроме того, количество проданных копий довольно мало (**чуть больше 2 млн** суммарно), а платформа выпуска (*GEN*) уже не существует. В связи с этим, данные строки можно удалить.

In [14]:
```python
data = data.dropna(subset=['genre'])
data.isna().sum()
```

Out[14]:
```
name                  0
platform              0
year_of_release     269
genre                 0
na_sales              0
eu_sales              0
jp_sales              0
other_sales           0
critic_score       8576
user_score         6699
rating             6764
total_sales           0
dtype: int64
```

Год выпуска

In [15]:
```python
data.query('year_of_release.isna()')
```

Out[15]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
183	Madden NFL 2004	PS2	NaN	Sports	4.26	0.26	0.01	0.71	94.0	8.5	E	5.24
377	FIFA Soccer 2004	PS2	NaN	Sports	0.59	2.36	0.04	0.51	84.0	6.4	E	3.50
456	LEGO Batman: The Videogame	Wii	NaN	Action	1.80	0.97	0.00	0.29	74.0	7.9	E10+	3.06
475	wwe Smackdown vs. Raw 2006	PS2	NaN	Fighting	1.57	1.02	0.00	0.41	NaN	NaN	NaN	3.00
609	Space Invaders	2600	NaN	Shooter	2.36	0.14	0.00	0.03	NaN	NaN	NaN	2.53
...	...	...	...	...	...	...	...	...	...	...	...	...
16373	PDC World Championship Darts 2008	PSP	NaN	Sports	0.01	0.00	0.00	0.00	43.0	tbd	E10+	0.01
16405	Freaky Flyers	GC	NaN	Racing	0.01	0.00	0.00	0.00	69.0	6.5	T	0.01
16448	Inversion	PC	NaN	Shooter	0.01	0.00	0.00	0.00	59.0	6.7	M	0.01
16458	Hakuouki: Shinsengumi Kitan	PS3	NaN	Adventure	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16522	Virtua Quest	GC	NaN	Role-Playing	0.01	0.00	0.00	0.00	55.0	5.5	T	0.01

269 rows × 12 columns

Рассмотрим, есть ли такая же информация об этих видеоиграх для других платформ.

In [16]:
```python
data.query('name == "Madden NFL 2004"')
```

Out[16]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
183	Madden NFL 2004	PS2	NaN	Sports	4.26	0.26	0.01	0.71	94.0	8.5	E	5.24
1881	Madden NFL 2004	XB	2003.0	Sports	1.02	0.02	0.00	0.05	92.0	8.3	E	1.09
3889	Madden NFL 2004	GC	2003.0	Sports	0.40	0.10	0.00	0.01	94.0	7.7	E	0.51
5708	Madden NFL 2004	GBA	2003.0	Sports	0.22	0.08	0.00	0.01	70.0	6.6	E	0.31

Как видим, как минимум в одном случае, для других платформ такая же информация имеется. В связи с этим, заполним недостающие значения теми же значениями, но для других платформ.

В связи с тем, что часто видеоигры могут быть временным эксклюзивом, а так же могут выпускать для некоторых платформ сильно позже других, то необходимо добавить дополнительное условие, что для всех остальных плафторм год выпуска был одним и тем же.

In [17]:
```python
for index, game in data.query('year_of_release.isna()').iterrows():
    name = game['name']
    matching_games = data.query('name == @name')
    if matching_games['year_of_release'].nunique() == 1:
        mean_year = matching_games['year_of_release'].mean()
        data.at[index, 'year_of_release'] = mean_year
```

In [18]:
```python
data.isna().sum()
```

Out[18]:
```
name                  0
platform              0
year_of_release     158
genre                 0
na_sales              0
eu_sales              0
jp_sales              0
other_sales           0
critic_score       8576
user_score         6699
rating             6764
total_sales           0
dtype: int64
```

Оставшиеся значения не представляется заполнить, но, учитывая, что их количество составляет меньше 1%, это не создаст проблем при анализе.

Оценки критиков

In [19]:
```python
data.query('critic_score.isna()')
```

Out[19]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77	NaN	NaN	NaN	40.24
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN	31.38
5	Tetris	GB	1989.0	Puzzle	23.20	2.26	4.22	0.58	NaN	NaN	NaN	30.26
9	Duck Hunt	NES	1984.0	Shooter	26.93	0.63	0.28	0.47	NaN	NaN	NaN	28.31
10	Nintendogs	DS	2005.0	Simulation	9.05	10.95	1.93	2.74	NaN	NaN	NaN	24.67
...	...	...	...	...	...	...	...	...	...	...	...	...
16710	Samurai Warriors: Sanada Maru	PS3	2016.0	Action	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16711	LMA Manager 2007	X360	2006.0	Sports	0.00	0.01	0.00	0.00	NaN	NaN	NaN	0.01
16712	Haitaka no Psychedelica	PSV	2016.0	Adventure	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16713	Spirits & Spells	GBA	2003.0	Platform	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16714	Winning Post 8 2016	PSV	2016.0	Simulation	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01

8576 rows × 12 columns

Рассмотрим распределение игр без оценок критиков по годам и сравним с общим количеством игр, выпускаемых в каждом году.

In [20]:
```python
fig, ax = plt.subplots(figsize=(12, 6))

ax.hist(
    data['year_of_release'],
    bins=30,
    alpha=0.5,
    label='Общее количество выпущенных игр',
    color='blue')
ax.hist(
    data.query('critic_score.isna()')['year_of_release'],
    bins=30,
    alpha=0.5,
    label='Без оценки критиков',
    color='red')

ax.set_xlabel('Год выпуска')
ax.set_ylabel('Количество игр')
ax.set_title('Количество игр без оценки критиков')
ax.legend()

plt.show()
```

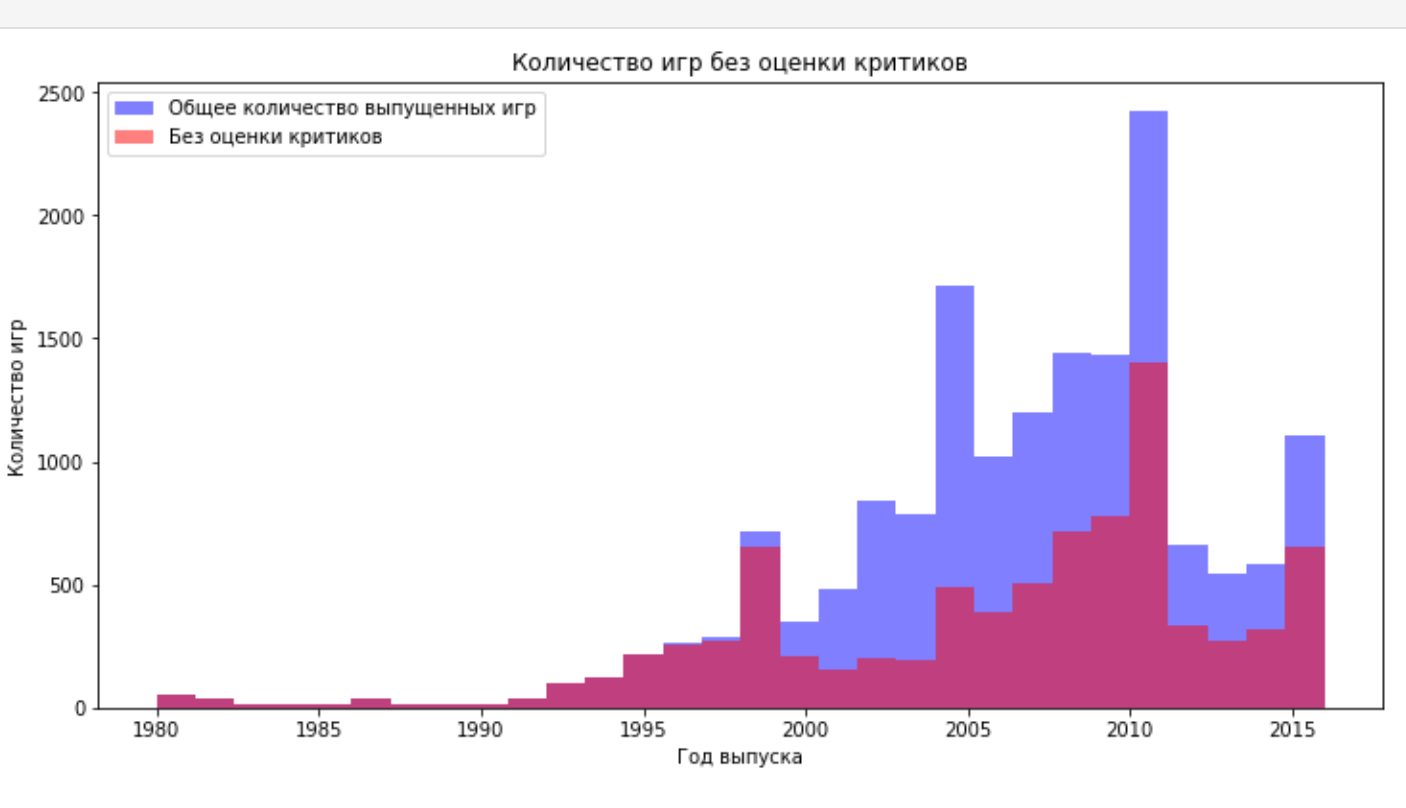

Как мы видим, до 1999 года у большинства игр отсутствуют оценки критиков. Более того, индустрия того периода уже мало похожа на нынешнюю, поэтому здесь пропуски можно оставить. Полсе 1999 года мы видим, что количество игр без оценок доходит до половины от всех выпущенных игр.

Рассмотрим количество игр без отзывов критиков по жанрам.

In [21]:
```python
data.groupby('genre').agg({'name':'count', 'critic_score':'count'}).plot(
    kind='bar',
    figsize=(12,6),
    xlabel='Жанр',
    ylabel= 'Количество игр'
)
plt.title('Количество игр разных жанров\nбез оценок критиков')
plt.legend(['Всего', 'Без отзывов'])
plt.show()
```

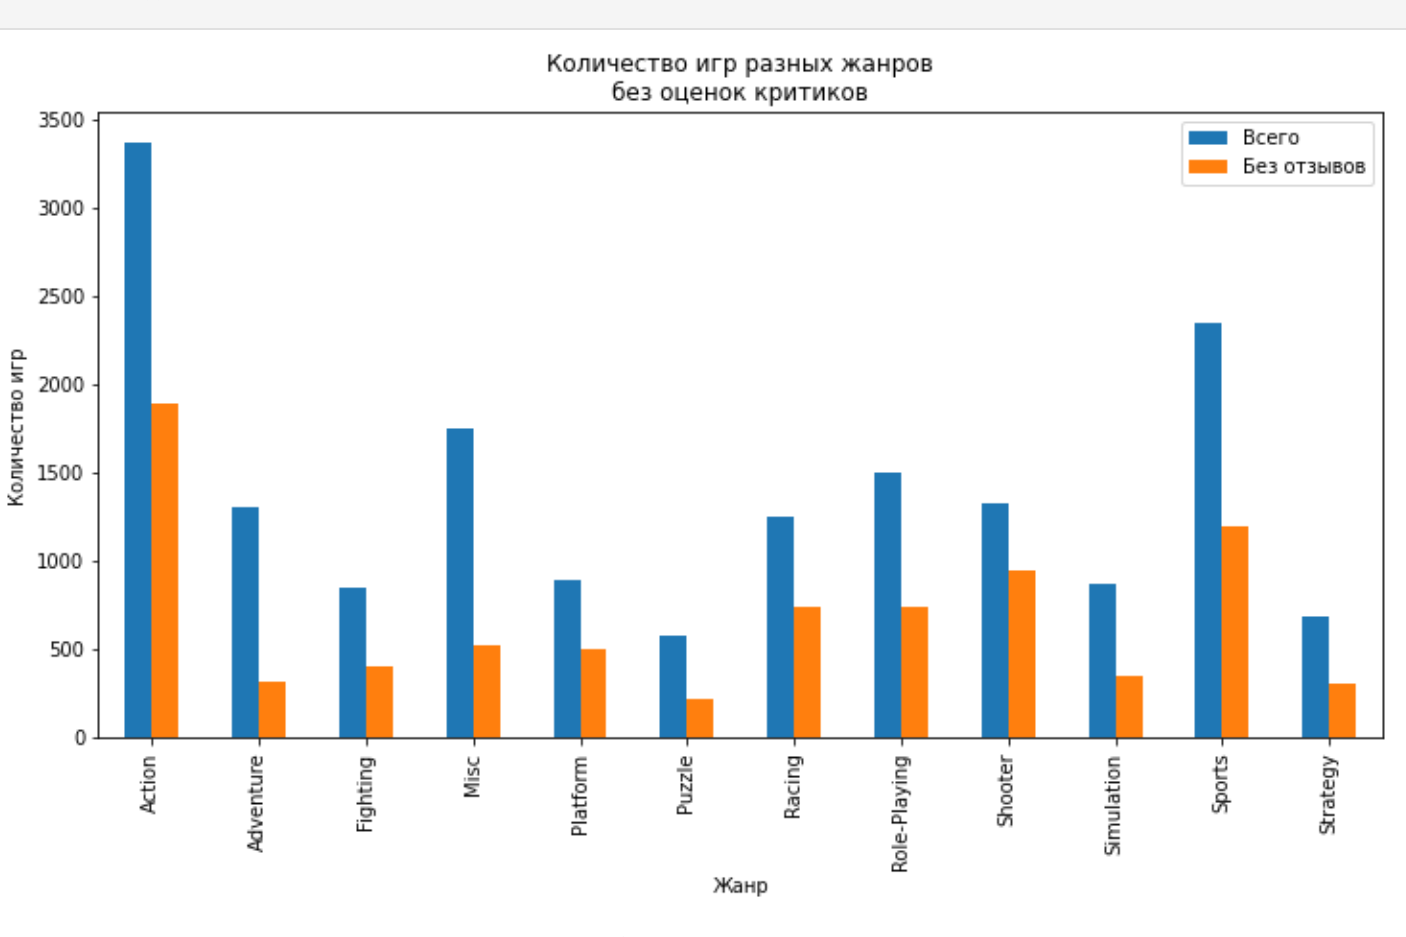

На данном графике видно, что количество игр без оценок составляет примерно ту же часть от всех игр.

Рассмотрим то же самое распределение относительно платформы.

In [22]:
```python
data.query('year_of_release >= 1999').groupby('platform').agg({'name':'count', 'critic_score':'count'}).plot(
    kind='bar',
    figsize=(12,6),
    xlabel='Платформа',
    ylabel= 'Количество игр',
)
plt.title('Количество игр на разных платформах\nбез оценок критиков')
plt.legend(['Всего', 'Без отзывов'])
plt.show()
```

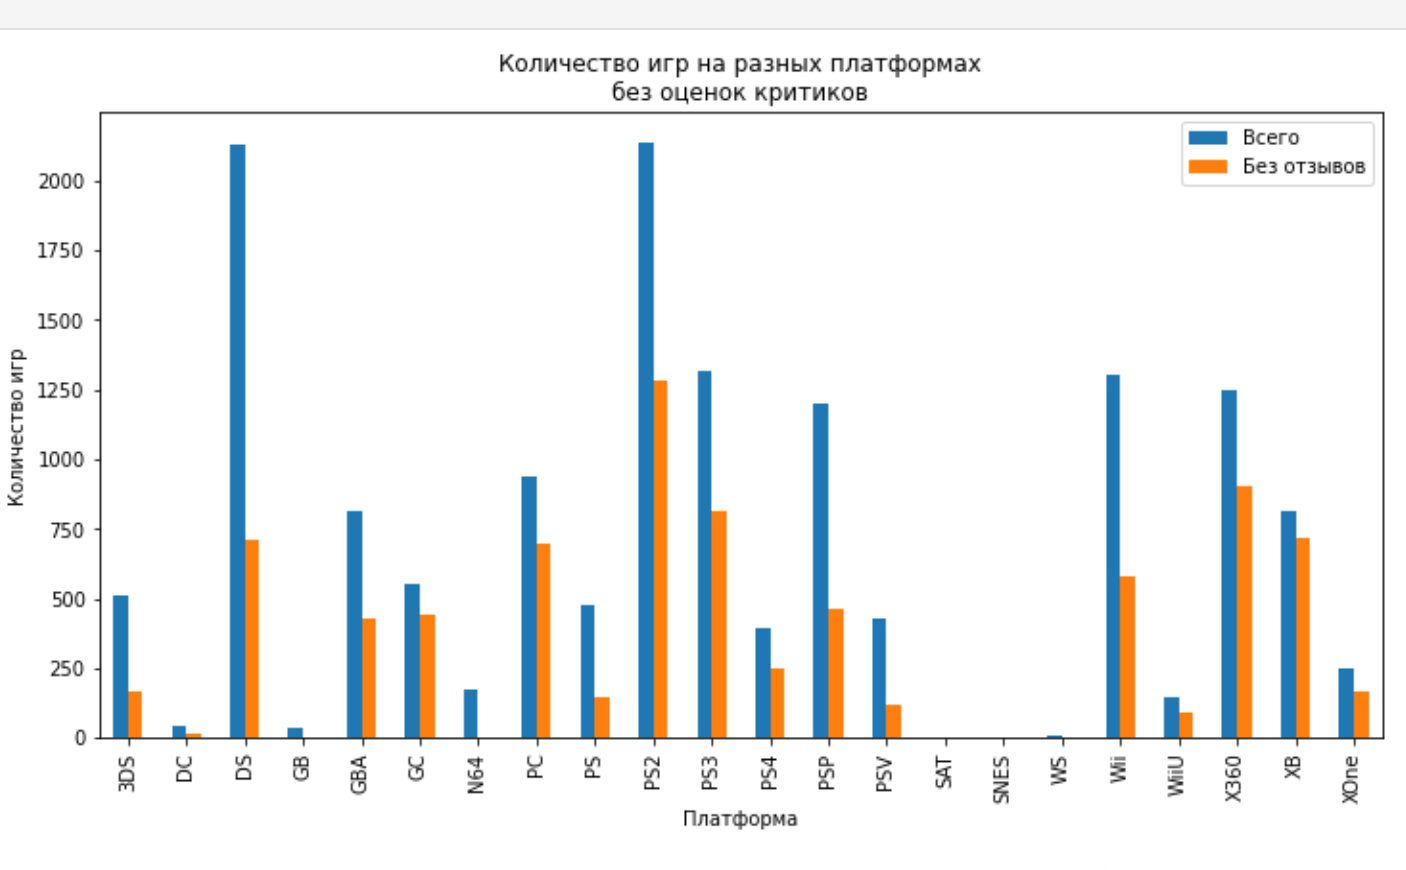

Как видно из графика, количество различных отзывов так же различется, причем у более современных платформ количество игр без оценок критиков больше.

В связи с этим, не представляется возможным заполнить данные пропуски какими-либо значениями.

Оценки пользователей

In [23]:
```python
data.query('user_score.isna()')
```

Out[23]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77	NaN	NaN	NaN	40.24
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN	31.38
5	Tetris	GB	1989.0	Puzzle	23.20	2.26	4.22	0.58	NaN	NaN	NaN	30.26
9	Duck Hunt	NES	1984.0	Shooter	26.93	0.63	0.28	0.47	NaN	NaN	NaN	28.31
10	Nintendogs	DS	2005.0	Simulation	9.05	10.95	1.93	2.74	NaN	NaN	NaN	24.67
...	...	...	...	...	...	...	...	...	...	...	...	...
16710	Samurai Warriors: Sanada Maru	PS3	2016.0	Action	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16711	LMA Manager 2007	X360	2006.0	Sports	0.00	0.01	0.00	0.00	NaN	NaN	NaN	0.01
16712	Haitaka no Psychedelica	PSV	2016.0	Adventure	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16713	Spirits & Spells	GBA	2003.0	Platform	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16714	Winning Post 8 2016	PSV	2016.0	Simulation	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01

6699 rows × 12 columns

Количество пропущенных значений оценок пользователей так же составляет значительную часть данных (**6700** строк).

Так же, как и в предыдущем случае, рассмотрим соотношение количества видеоигр без пользовательских оценок и общего числа игр относительно года выпуска, жанра и платформы.

In [24]:
```python
data.query('user_score.isna()')['year_of_release'].value_counts()
data['year_of_release'].value_counts()

fig, ax = plt.subplots(figsize=(12, 6))

ax.hist(
    data['year_of_release'],
    bins=30,
    alpha=0.5,
    label='Общее количество выпущенных игр',
    color='blue')

ax.hist(
    data.query('user_score.isna()')['year_of_release'],
    bins=30,
    alpha=0.5,
    label='Без оценки пользователей',
    color='red')

ax.set_xlabel('Год выпуска')
ax.set_ylabel('Количество игр')
ax.set_title('Количество игр без оценки пользователей')
ax.legend()

plt.show()
```

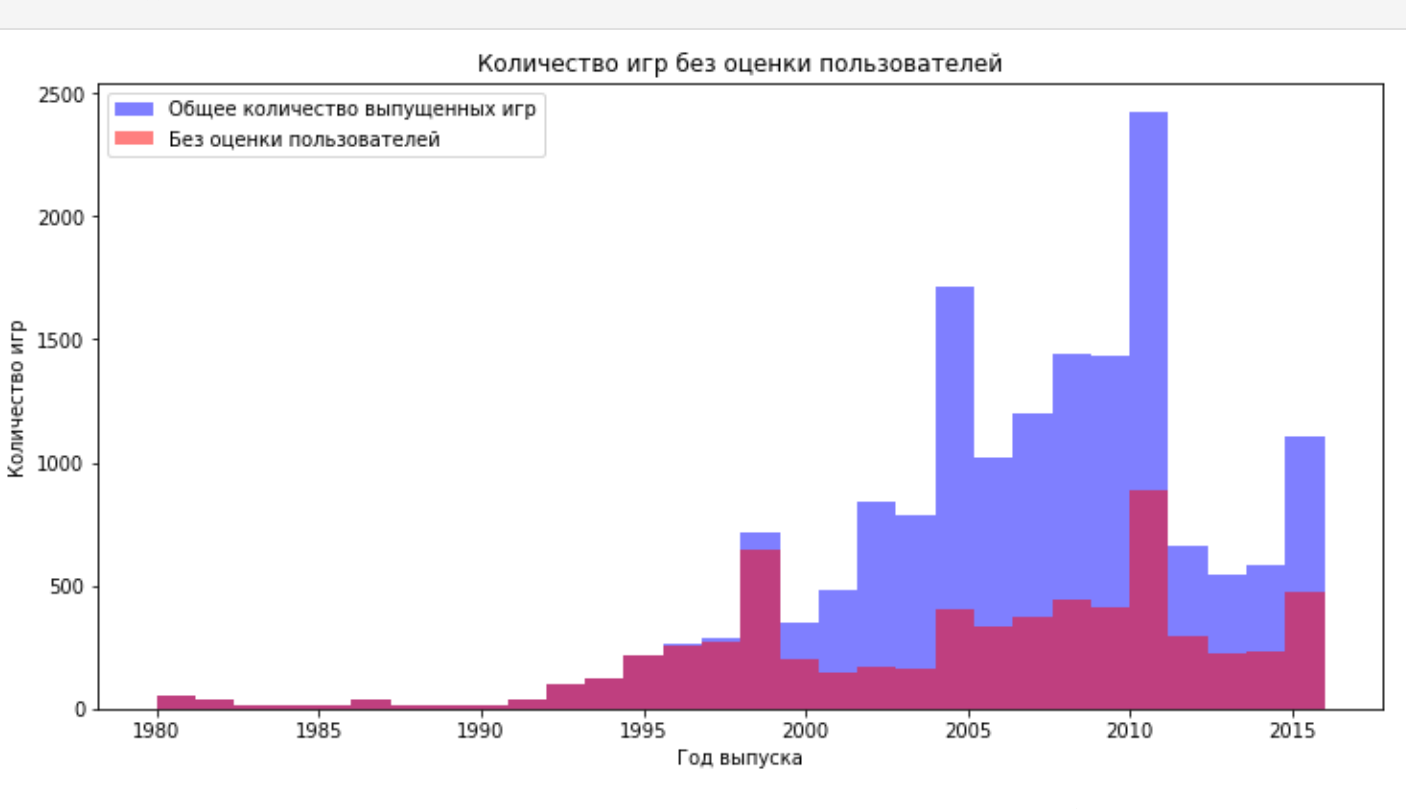

В целом, тенденция по годам сохраняется, но с 1999 года меньшая часть игр от общего числа не имеет оценок пользователей.

Рассмотрим игры по жанрам и платформам.

In [25]:
```python
fig, axs = plt.subplots(1, 2, figsize=(12, 6))
fig.suptitle('Количество игр без оценок пользователей относительно жанра и платформы выпуска')
data.groupby('genre').agg({'name':'count', 'user_score':'count'}).plot(
    kind='bar',
    xlabel='Жанр',
    ylabel= 'Количество игр',
    ax =axs[0]
)
axs[0].legend(['Всего', 'Без отзывов'])

data.query('year_of_release >= 1999').groupby('platform').agg({'name':'count', 'user_score':'count'}).plot(
    kind='bar',
    xlabel='Платформа',
    ylabel= 'Количество игр',
    ax=axs[1]
)
axs[1].legend(['Всего', 'Без отзывов'])
plt.show()
```

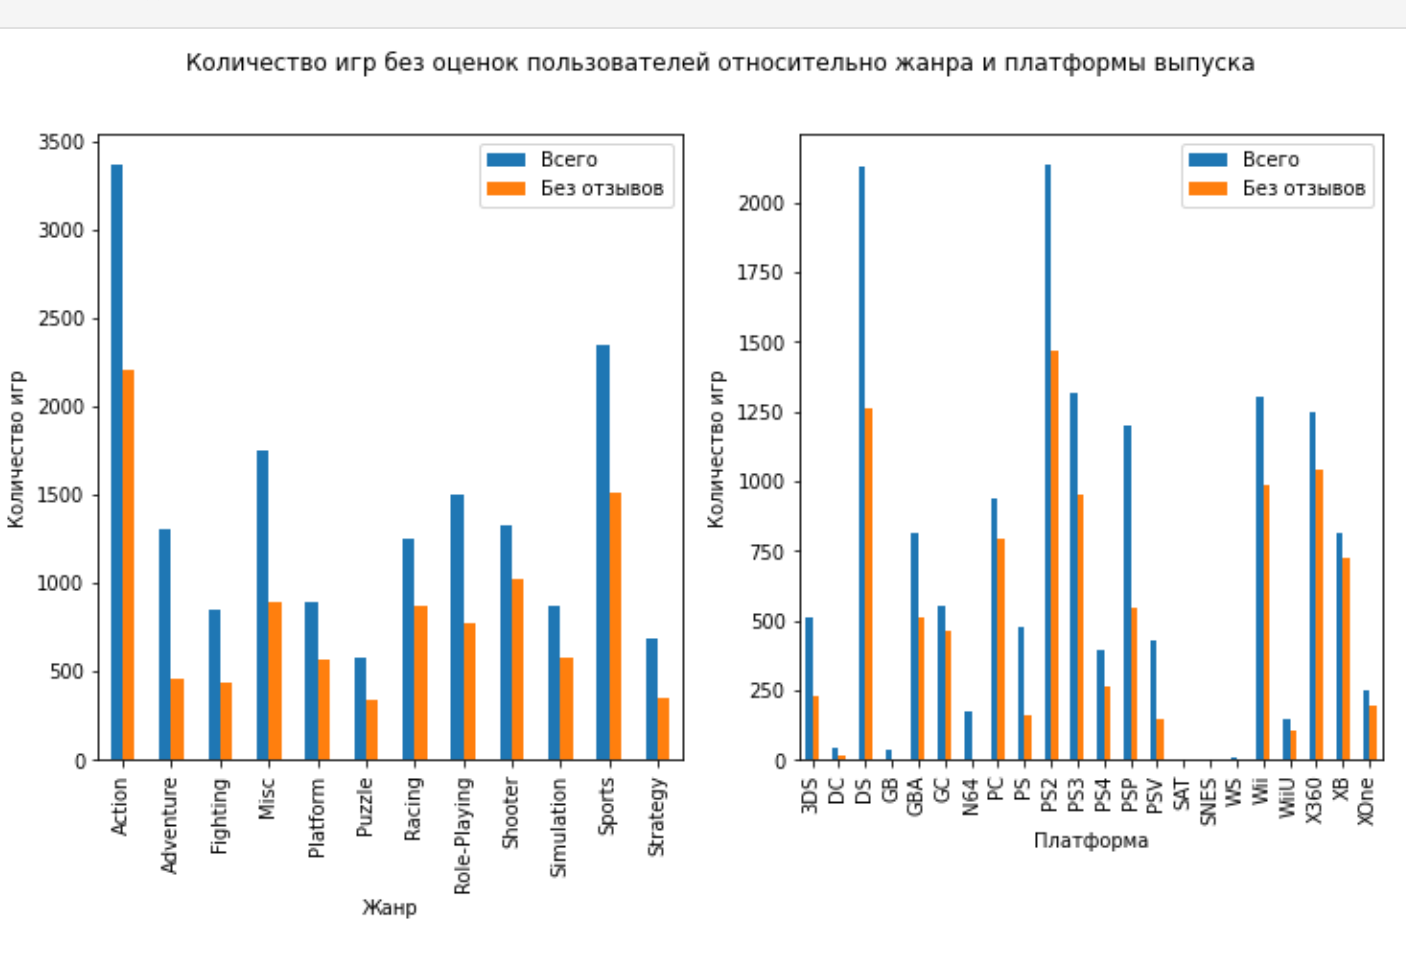

Та же самая картина, что и в случае с оценками критиков, наблюдается и с оценками пользователей.

Вывод тот же - придется оставить эти столбцы пустыми.

Возрастной рейтинг

In [26]:
```python
data.query('rating.isna()')
```

Out[26]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77	NaN	NaN	NaN	40.24
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN	31.38
5	Tetris	GB	1989.0	Puzzle	23.20	2.26	4.22	0.58	NaN	NaN	NaN	30.26
9	Duck Hunt	NES	1984.0	Shooter	26.93	0.63	0.28	0.47	NaN	NaN	NaN	28.31
10	Nintendogs	DS	2005.0	Simulation	9.05	10.95	1.93	2.74	NaN	NaN	NaN	24.67
...	...	...	...	...	...	...	...	...	...	...	...	...
16710	Samurai Warriors: Sanada Maru	PS3	2016.0	Action	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16711	LMA Manager 2007	X360	2006.0	Sports	0.00	0.01	0.00	0.00	NaN	NaN	NaN	0.01
16712	Haitaka no Psychedelica	PSV	2016.0	Adventure	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16713	Spirits & Spells	GBA	2003.0	Platform	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16714	Winning Post 8 2016	PSV	2016.0	Simulation	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01

6764 rows × 12 columns

Информация о рейтинге отсутствует примерно 6764 случаях. Поскольку сама организация ESRB появилась лишь в 1994 году, неудивительно, что так много игр не имеет рейтинга. Рассмотрим, у скольких игр после 1994 года отсутствует рейтинг.

In [27]:
```python
data.query('year_of_release >= 1994 and rating.isna()')
```

Out[27]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN	31.38
10	Nintendogs	DS	2005.0	Simulation	9.05	10.95	1.93	2.74	NaN	NaN	NaN	24.67
12	Pokemon Gold/Pokemon Silver	GB	1999.0	Role-Playing	9.00	6.18	7.20	0.71	NaN	NaN	NaN	23.09
20	Pokemon Diamond/Pokemon Pearl	DS	2006.0	Role-Playing	6.38	4.46	6.04	1.36	NaN	NaN	NaN	18.24
25	Pokemon Ruby/Pokemon Sapphire	GBA	2002.0	Role-Playing	6.06	3.90	5.38	0.50	NaN	NaN	NaN	15.84
...	...	...	...	...	...	...	...	...	...	...	...	...
16710	Samurai Warriors: Sanada Maru	PS3	2016.0	Action	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16711	LMA Manager 2007	X360	2006.0	Sports	0.00	0.01	0.00	0.00	NaN	NaN	NaN	0.01
16712	Haitaka no Psychedelica	PSV	2016.0	Adventure	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16713	Spirits & Spells	GBA	2003.0	Platform	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16714	Winning Post 8 2016	PSV	2016.0	Simulation	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01

6334 rows × 12 columns

Таких позиций все равно очень много - **6334**. Попробуем проставить часть значений таким же методом, что был использован при заполнении пропусков в дате релиза.

In [28]:
```python
for index, game in data.query('rating.isna()').iterrows():
    name = game['name']
    matching_games = data.query('name == @name')
    if len(matching_games['rating']) > 0:
        data.at[index, 'rating'] = matching_games['rating'].iloc[0]
```

In [29]:
```python
data.query('year_of_release >= 1994 and rating.isna()')
```

Out[29]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN	31.38
10	Nintendogs	DS	2005.0	Simulation	9.05	10.95	1.93	2.74	NaN	NaN	NaN	24.67
12	Pokemon Gold/Pokemon Silver	GB	1999.0	Role-Playing	9.00	6.18	7.20	0.71	NaN	NaN	NaN	23.09
20	Pokemon Diamond/Pokemon Pearl	DS	2006.0	Role-Playing	6.38	4.46	6.04	1.36	NaN	NaN	NaN	18.24
25	Pokemon Ruby/Pokemon Sapphire	GBA	2002.0	Role-Playing	6.06	3.90	5.38	0.50	NaN	NaN	NaN	15.84
...	...	...	...	...	...	...	...	...	...	...	...	...
16710	Samurai Warriors: Sanada Maru	PS3	2016.0	Action	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16711	LMA Manager 2007	X360	2006.0	Sports	0.00	0.01	0.00	0.00	NaN	NaN	NaN	0.01
16712	Haitaka no Psychedelica	PSV	2016.0	Adventure	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01
16713	Spirits & Spells	GBA	2003.0	Platform	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16714	Winning Post 8 2016	PSV	2016.0	Simulation	0.00	0.00	0.01	0.00	NaN	NaN	NaN	0.01

6072 rows × 12 columns

Осталось **6072** незаполненных значения.

Возможно, часть из этих игр выпускается исключительно для Японского или Европейского рынка, в таком случае, она не имеет рейтинга ESRB, поскольку он выдается только для игр, продающихся в Северной Америке.

Проверим это и заменим пропуски в этом случае на eu_raitng или jp_rating.

In [30]:
```python
for index, game in data.iterrows():
    if game['na_sales'] == 0:
        data.at[index, 'rating'] = 'no_us_rating'

data.query('rating.isna()')
```

Out[30]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
1	Super Mario Bros.	NES	1985.0	Platform	29.08	3.58	6.81	0.77	NaN	NaN	NaN	40.24
4	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	11.27	8.89	10.22	1.00	NaN	NaN	NaN	31.38
5	Tetris	GB	1989.0	Puzzle	23.20	2.26	4.22	0.58	NaN	NaN	NaN	30.26
9	Duck Hunt	NES	1984.0	Shooter	26.93	0.63	0.28	0.47	NaN	NaN	NaN	28.31
10	Nintendogs	DS	2005.0	Simulation	9.05	10.95	1.93	2.74	NaN	NaN	NaN	24.67
...	...	...	...	...	...	...	...	...	...	...	...	...
16675	Original Frisbee Disc Sports: Ultimate & Golf	DS	2007.0	Action	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16693	PGA European Tour	N64	2000.0	Sports	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16694	Carmageddon 64	N64	1999.0	Action	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16708	Woody Woodpecker in Crazy Castle 5	GBA	2002.0	Platform	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01
16713	Spirits & Spells	GBA	2003.0	Platform	0.01	0.00	0.00	0.00	NaN	NaN	NaN	0.01

2848 rows × 12 columns

Таким образом, мы смогли заполнить половину пропусков и в дальнейшем учитывать эти данные для понимания влияния рейтинга в регионах.

Изменение типа данных

Еще раз рассмотрим информацию о таблице.

In [31]:
```python
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 16712 entries, 0 to 16714
Data columns (total 12 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   name             16712 non-null  object
 1   platform         16712 non-null  object
 2   year_of_release  16554 non-null  float64
 3   genre            16712 non-null  object
 4   na_sales         16712 non-null  float64
 5   eu_sales         16712 non-null  float64
 6   jp_sales         16712 non-null  float64
 7   other_sales      16712 non-null  float64
 8   critic_score     8136 non-null   float64
 9   user_score       10013 non-null  object
 10  rating           13864 non-null  object
 11  total_sales      16712 non-null  float64
dtypes: float64(7), object(5)
memory usage: 2.2+ MB
```

В таблице есть два столбца, в которых необходимо поменять тип данных: **год выпуска** заменим целочисленным типом, **оценки пользователей** заменим на вещественный тип.

Для начала, заменим год релиза на целочисленный тип, поскольку это год, и он может быть только целым.

In [32]:
```python
data['year_of_release'] = data['year_of_release'].astype('Int64')
```

In [33]:
```python
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 16712 entries, 0 to 16714
Data columns (total 12 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   name             16712 non-null  object
 1   platform         16712 non-null  object
 2   year_of_release  16554 non-null  Int64
 3   genre            16712 non-null  object
 4   na_sales         16712 non-null  float64
 5   eu_sales         16712 non-null  float64
 6   jp_sales         16712 non-null  float64
 7   other_sales      16712 non-null  float64
 8   critic_score     8136 non-null   float64
 9   user_score       10013 non-null  object
 10  rating           13864 non-null  object
 11  total_sales      16712 non-null  float64
dtypes: Int64(1), float64(6), object(5)
memory usage: 2.2+ MB
```

Рассмотрим значения в столбце с оценками пользователей.

In [34]:
```python
data['user_score'].unique()
```

Out[34]:
```
array(['8', nan, '8.3', '8.5', '6.6', '8.4', '8.6', '7.7', '6.3', '7.4',
       '8.2', '9', '7.9', '8.1', '8.7', '7.1', '3.4', '5.3', '4.8', '3.2',
       '8.9', '6.4', '7.8', '7.5', '2.6', '7.2', '9.2', '7', '7.3', '4.3',
       '7.6', '5.7', '5', '9.1', '6.5', 'tbd', '8.8', '6.9', '9.4', '6.8',
       '6.1', '6.7', '5.4', '4', '4.9', '4.5', '9.3', '6.2', '4.2', '6',
       '3.7', '4.1', '5.8', '5.6', '5.5', '4.4', '4.6', '5.9', '3.9',
       '3.1', '2.9', '5.2', '3.3', '4.7', '5.1', '3.5', '2.5', '1.9', '3',
       '2.7', '2.2', '2', '9.5', '2.1', '3.6', '2.8', '1.8', '3.8', '0',
       '1.6', '9.6', '2.4', '1.7', '1.1', '0.3', '1.5', '0.7', '1.2',
       '2.3', '0.5', '1.3', '0.2', '0.6', '1.4', '0.9', '1', '9.7'],
      dtype=object)
```

Тут, помимо отсутствующих значений, имеется значение **tbd**.

"TBD" - это аббревиатура, означающая "To Be Determined", что в переводе на русский язык означает "Будет определено". В контексте видеоигр "TBD" используется для указания того, что пользовательская оценка для конкретной игры ещё не была определена или закреплена.

Обычно пользовательские оценки определяются путем агрегирования рейтингов и отзывов, отправленных игроками на определенной платформе или веб-сайте. Когда игра только вышла, может потребоваться время, чтобы достаточно пользователей сыграло в игру и оставило оценку, чтобы можно было рассчитать надежный рейтинг. В таких случаях пользовательский рейтинг может быть отображен как "TBD", пока не будет собрано достаточно оценок пользователей, чтобы определить точный рейтинг.

Посчитаем количество таких значений.

In [35]:
```python
len(data.query('user_score == "tbd"'))
```

Out[35]:
```
2424
```

Таких значений **2424**. Заменить их на какое-либо значение не представляется возможным, поэтому при замене типов заменим tbd на пустые значения.

In [36]:
```
data['user_score'] = pd.to_numeric(data['user_score'], errors='coerce')
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 16712 entries, 0 to 16714
Data columns (total 12 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   name             16712 non-null  object
 1   platform         16712 non-null  object
 2   year_of_release  16554 non-null  Int64
 3   genre            16712 non-null  object
 4   na_sales         16712 non-null  float64
 5   eu_sales         16712 non-null  float64
 6   jp_sales         16712 non-null  float64
 7   other_sales      16712 non-null  float64
 8   critic_score     8136 non-null   float64
 9   user_score       7589 non-null   float64
 10  rating           13864 non-null  object
 11  total_sales      16712 non-null  float64
dtypes: Int64(1), float64(7), object(4)
memory usage: 2.2+ MB
```

Теперь все данные приведены к нужным типам.

Выводы предобработки данных

В ходе предобработки данных было решено несколько задач.

Все названия столбцов были приведены к формату `snake_case`.
Была выполнена проверка на наличие явных дубликатов, проверка показала, что такие данные отсутствуют. Неявные дубликаты были проверены по совпадениям одновременно названия, платформы и года релиза и были удалены. В таблицу был добавлен столбец с общими продажами игр по всем регионам.

Проверка пропусков показала, что в **6** столбцах присутствуют пропуски. Больше всего пропусков в столбце с оценками критиков (**8578**), чуть меньше пропусков в столбцах с оценками пользователей и возрастным рейтингом (**~6700**). По **1** пропуска в информации о названии видеоигры и жанра. Год выпуска не указан для **269** строк. Пропуски в названиях видеоигр и их жанрах оказались в одних строках, которые были удалены. Данное удаление не повлияет на дальнейший анализ, поскольку у этих видеоигр малые продажи, год выпуска у обеих игр 1993, а платформа, для которой выпускались данные игры, уже не выпускается и является устаревшей.

Пропуски в годе выпуска игр были заменены на год выпуска у тех же игр для других платформ, при этом была выполнена проверка, что все остальные платформы получили эту игру в один год. Таким образом, мы удостоверились, что возможная временная эксклюзивность игры для какой-либо платформы не повлияет на неверное заполнение пропусков. В итоге, в данном столбце осталось **158** пустых значений. ***Причиной пропусков в данном столбце могут говорить лишь о технической проблеме при получении данных, поскольку у всех игр, уже выпущенных и продающихся, известен год их выпуска***.

Пропуски в оценках критиков и пользователей не удалось заполнить, поскольку нет путей для точного заполнения данных значений. ***В данном случае причиной пропуска, помимо технической причины, может быть то, что данная игра вышла очень давно и на тот момент не существовало агрегаторов оценок критиков и пользователей***.

Пропуски в значениях рейтинга были заполнены на основании имеющихся данных о рейтинге игр для других платформ. Это помогло заполнить часть пропусков, но все равно осталось **6072** незаполненных значения. Кроме того, часть игр не выпускалась на рынках Северной Америки, что тоже привело к отсутствию рейтинга в таблице. Такие значения были заполнены соответственной заглушкой. ***В этом случае причиной прпоуска, помимо технической, может быть то, что самая организация, выдающая рейтинг, была основана лишь в 1993 году, то есть все игры до этого не имели какой-либо унифицированной шкалы по возрастному рейтингу, а так же то, что игра не выпускалась на рынках Северной Америки, а следовательно, ей не присваивался рейтинг***.

После обработки пропусков некоторые столбцы были приведены к новым типам для облегчения дальнейшего анализа: тип значений в столбце **год выпуска** был заменен на целочисленный, а значения в столбце с **оценками пользователей** был заменен на вещественный тип. При этом, в столбце с оценками пользователей присутствовали занчения **tbd**, что означает недостаточное количество имеющихся оценок для подсчета среднего. В этом случае значения были заменены на `NaN`.

Исследовательский анализ данных

Выпуск игр по годам

Рассмотрим, как менялось количество выпущенных игр по годам.

In [38]:
```
data.groupby('year_of_release').agg({'name':['count', 'nunique']}).plot(
    kind='bar',
    figsize=(12,6),
)
plt.title('Распределение количества выпущенных игр по годам')
plt.legend(['Общее количество игр для всех платформ', 'Уникальные игры'])
plt.xlabel('Год выпуска')
plt.ylabel('Количество выпущенных игр')
plt.show()
```

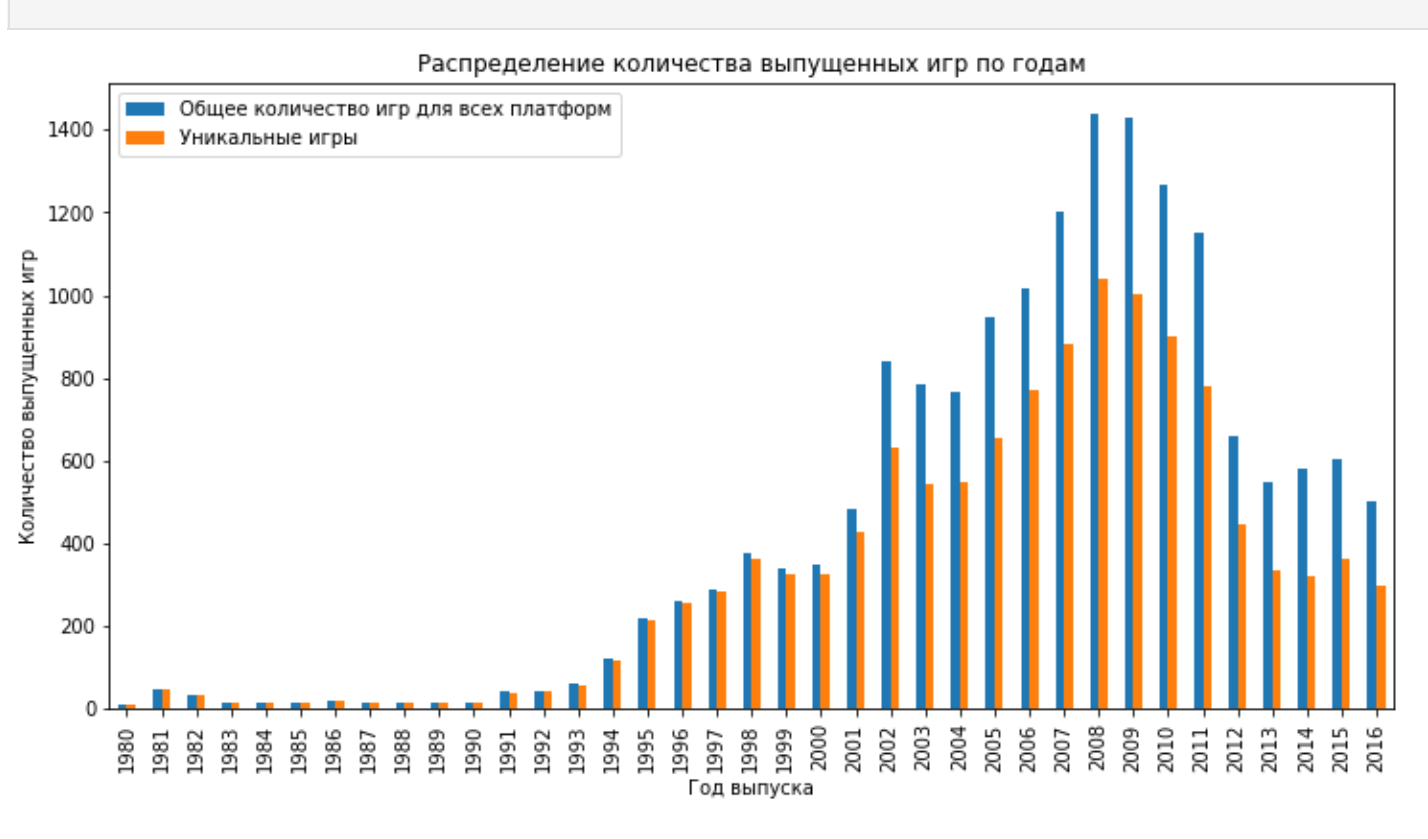

Как мы видим, до **1993** в год выпускалось довольно мало игр, не больше 50 наименований в год. Затем, до **2008** года был рост, когда количество выпущенных за год игр превысило 1400 выпущенных игр. После чего началось снижение, и с **2012** года в среднем выпускается порядка **500** игр в год. Кроме того, можно заметить, что до **2000** года количество игр и их версий для различных платформ практически совпадало, после чего началось значительное увеличение выпуска одних и тех же игр для различных платформ. При этом, тенденция для обоих значений одинаковая.

На основании этого графика, можно сделать вывод, что рассматривать продажи игр до **2002** года нерелевантно. Начиная с этого периода, соотношение количества игр совокупно для всех платформ и уникальных игр примерно одинаково.

Изменение продаж по платформам

Построим сводную таблицу по продажам игр для различных платформ.

In [39]:
```
data_pivot = data.pivot_table(
    index=['platform', 'year_of_release'],
    values='total_sales',
    aggfunc='sum'
)
data_pivot
```

Out[39]:

		total_sales
platform	**year_of_release**	
2600	**1980**	11.38
	1981	35.68
	1982	28.88
	1983	5.84
	1984	0.27
...	**...**	...
XB	**2008**	0.18
XOne	**2013**	18.96
	2014	54.07
	2015	60.14
	2016	26.15

241 rows × 1 columns

In [40]:
```
platform_sales_pivot = data_pivot.pivot_table(index='platform', columns='year_of_release', values='total_sales')

fig = make_subplots(
    rows=1,
    cols=1
)

trace = go.Heatmap(
    z=platform_sales_pivot.values,
    x=platform_sales_pivot.columns,
    y=platform_sales_pivot.index,
    colorscale='Viridis'
)
fig.append_trace(trace, row=1, col=1)
fig.update_layout(
    autosize=False,
    width=900,
    height=600,
    title=dict(text='Общие продажи по платформам и годам'),
    title_x=0.5,
    title_y=0.9,
    xaxis=dict(title='Год'),
    yaxis=dict(title='Платформа')
)
fig.show()
```

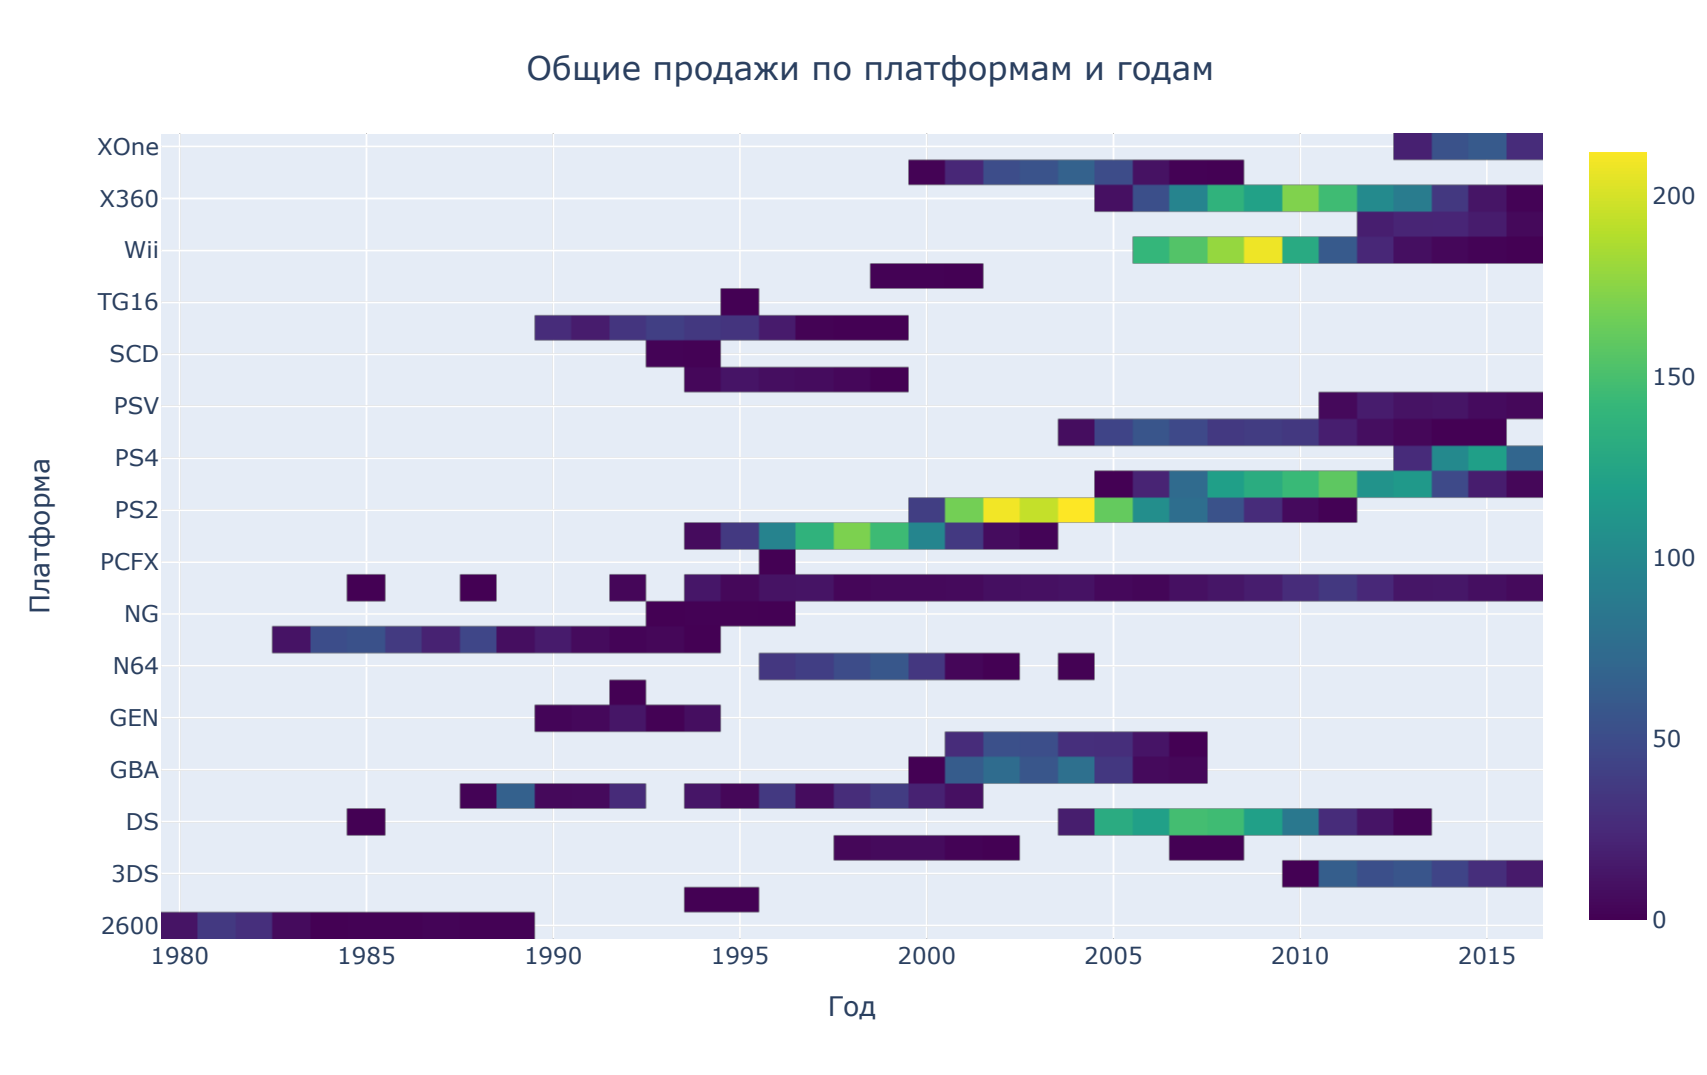

На графике видно наличие "артефакта" - игры на Nintendo DS, выпущенной в 1985 году. Согласно официальной истории, данная приставка появилась только в 2004 году, следовательно, это ошибка в данных. Поскольку продажи в этом году малы и составляют 0.02 млн копий, удалим эти данные.

In [41]:
```
data.drop(index= data.loc[(data['platform'] == 'DS') & (data['year_of_release'] < 2004)].index, inplace=True)
```

In [42]:
```
data_pivot = data.pivot_table(
    index=['platform', 'year_of_release'],
    values='total_sales',
    aggfunc='sum'
)
data_pivot

platform_sales_pivot = data_pivot.pivot_table(index='platform', columns='year_of_release', values='total_sales')

fig = make_subplots(
    rows=1,
    cols=1
)

trace = go.Heatmap(
    z=platform_sales_pivot.values,
    x=platform_sales_pivot.columns,
    y=platform_sales_pivot.index,
    colorscale='Viridis'
)
fig.append_trace(trace, row=1, col=1)
fig.update_layout(
    autosize=False,
    width=900,
    height=600,
    title=dict(text='Общие продажи по платформам и годам'),
    title_x=0.5,
    title_y=0.9,
    xaxis=dict(title='Год'),
    yaxis=dict(title='Платформа')
)
fig.show()
```

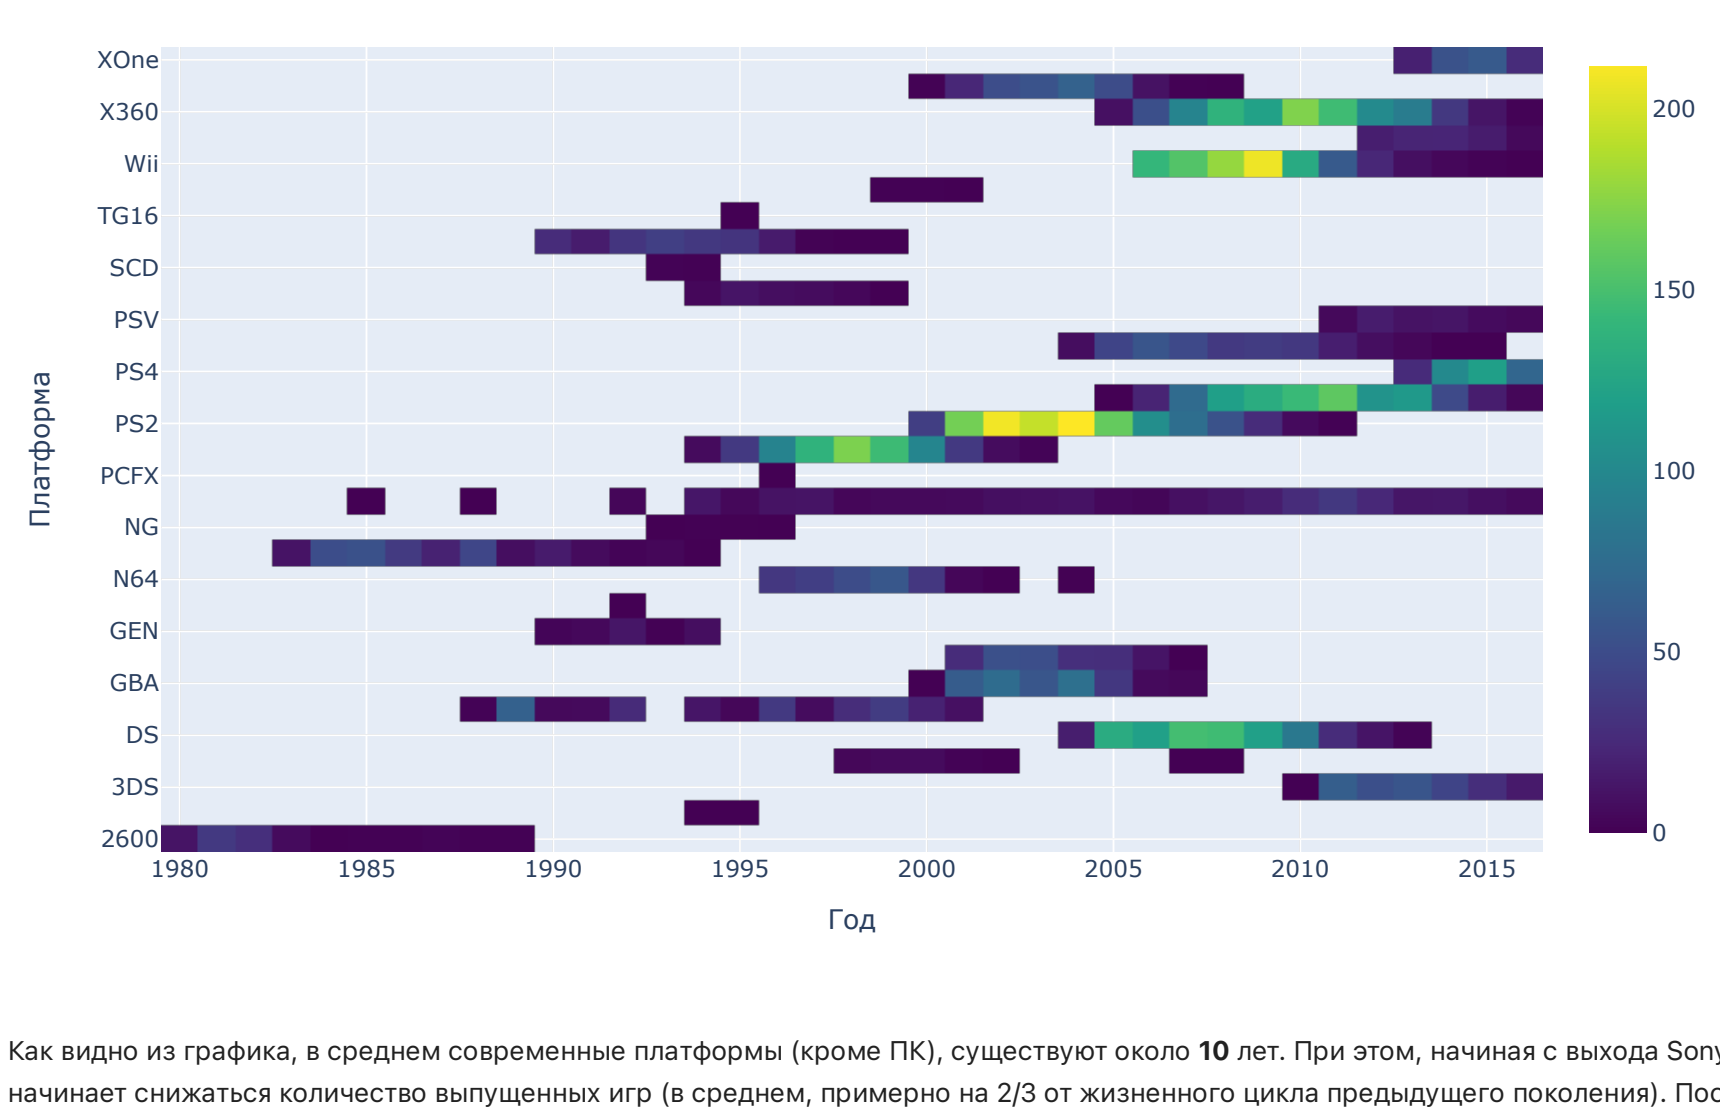

Как видно из графика, в среднем современные платформы (кроме ПК), существуют около **10** лет. При этом, начиная с выхода Sony PlayStation, новые поколения платформ выходят в год, когда начинает снижаться количество выпущенных игр (в среднем, примерно на 2/3 от жизненного цикла предыдущего поколения). Посчитаем точно жизненный цикл платформ.

In [43]:
```
time_life = data.pivot_table(index='platform', values='year_of_release', aggfunc=['min', 'max']).reset_index()
time_life['life'] = time_life['max'] - time_life['min'] + 1 # в срок жизни платформы, должны входить границы диапазона,
                                                            # поэтому +1
time_life['life'].median()
```

Out[43]:
```
8.0
```

Таким образом, медианное время жизненного цикла плафторм составляет 8 лет, что немного меньше приблизительной оценки.

Рассмотрим общие продажи по платформам за все время.

In [45]:
```
data_pivot.pivot_table(
    index='platform',
    values='total_sales',
    aggfunc='sum'
).sort_values(by='total_sales', ascending=False).head(10)
```

Out[45]:

	total_sales
platform	
PS2	1245.96
X360	966.61
PS3	934.70
Wii	903.31
DS	804.26
PS	727.58
PS4	314.14
GBA	313.73
PSP	292.77
3DS	258.51

Можно выделить 6 платформ с наибольшими продажами видеоигр за все время. Лидером, причем с большим отрывом (*до ближайшей платформы почти **300** млн копий*), является PS2. Затем, с разницей между продажами в **30 млн.**, XBox 360, PS3 и Wii. Nintendo DS и PlayStation замыкают список с **804** и **727** млн копий соответственно.
В целом, этими платформами можно описать весь современный промежуток игростроения. Характерно, что PS4, XBox One и WiiU имеют гораздо меньшее количество проданных копий, поскольку их старт начался относительно недавно, а следовательно, не все пользователи еще перешли на новое поколение.

Построим распределение продаж для этих платформ по годам, включив новейшие поколения.

In [46]:
```
platforms_list = list(data.groupby('platform')['total_sales'].sum().sort_values(ascending=False).index[:9]) + ['XOne', 'WiiU']
top_platforms_pivot = data[data['platform'].isin(platforms_list)].pivot_table(
    index=['platform', 'year_of_release'],
    values='total_sales',
    aggfunc='sum'
)

top_platform_sales_pivot = top_platforms_pivot.pivot_table(
    index='platform',
    columns='year_of_release',
    values='total_sales'
)

fig = make_subplots(
    rows=1,
    cols=1,
)
trace = go.Heatmap(
    z=top_platform_sales_pivot.values,
    x=top_platform_sales_pivot.columns,
    y=top_platform_sales_pivot.index,
    colorscale='Viridis'
)
fig.append_trace(trace, row=1, col=1)
fig.update_layout(
    autosize=False,
    width=900,
    height=600,
    title=dict(text='Общие продажи на популярных и новых платформах за все время'),
    title_x=0.5,
    title_y=0.9,
    xaxis=dict(title='Год'),
    yaxis=dict(title='Платформа')
)
fig.show()
```

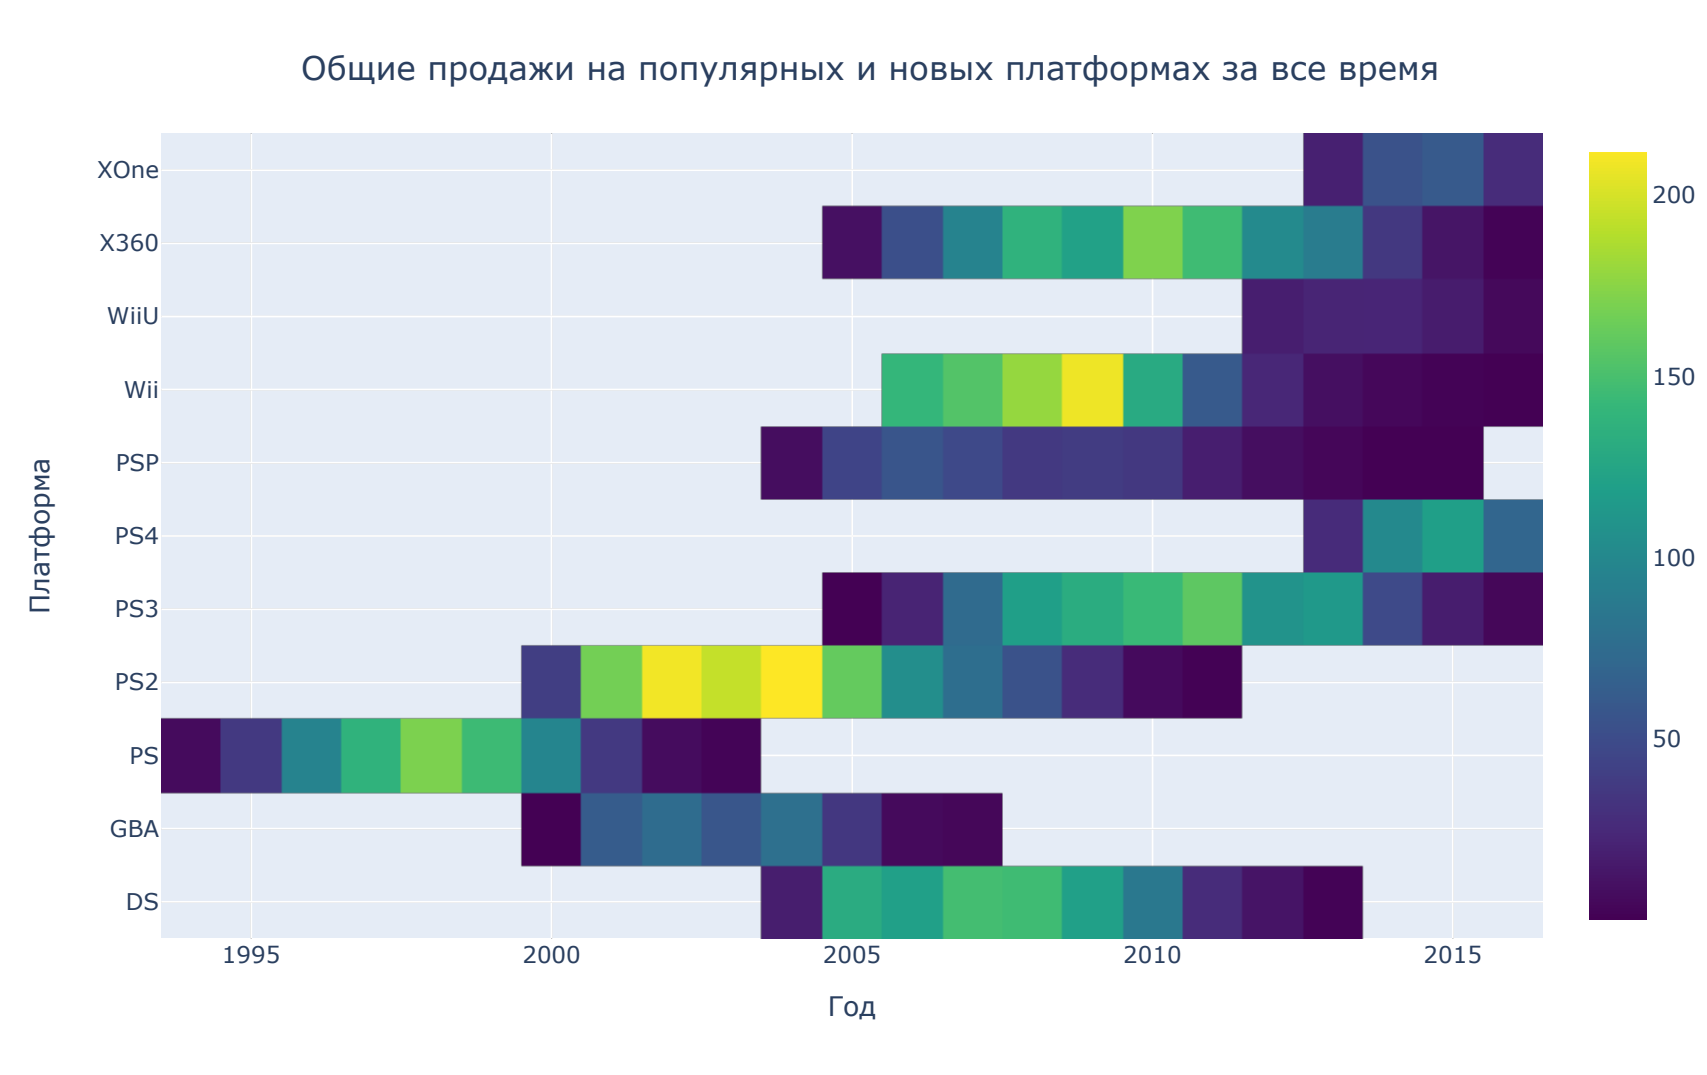

Как мы видим, и правда с выхода PlayStation 2 в 2000 году, новые поколения платформ начинают продаваться в второй трети жизненного цикла предыдущей.

Выбор актуального периода

По проведенному ранее анализу можно сделать вывод, что в 2017 году продажи игр на новое поколение приставок (*PS4, XBox One, WiiU*) выйдут на значения, близкие к пиковым. Поэтому, логично ***определить актуальным преиод с 2012 по 2016***. Таким образом, мы можем увидеть тенденции на платформах, являющихся самыми актуальными, при этом не испортив анализ более устаревшими данными.

In [48]:
```
actual_period_data = data[data['year_of_release'].isin(range(2012,2017))]
actual_period_data
```

Out[48]:

	name	platform	year_of_release	genre	na_sales	eu_sales	jp_sales	other_sales	critic_score	user_score	rating	total_sales
16	Grand Theft Auto V	PS3	2013	Action	7.02	9.09	0.98	3.96	97.0	8.2	M	21.05
23	Grand Theft Auto V	X360	2013	Action	9.66	5.14	0.06	1.41	97.0	8.1	M	16.27
31	Call of Duty: Black Ops 3	PS4	2015	Shooter	6.03	5.86	0.36	2.38	NaN	NaN	NaN	14.63
33	Pokemon X/Pokemon Y	3DS	2013	Role-Playing	5.28	4.19	4.35	0.78	NaN	NaN	NaN	14.60
34	Call of Duty: Black Ops II	PS3	2012	Shooter	4.99	5.73	0.65	2.42	83.0	5.3	M	13.79
...	...	...	...	...	...	...	...	...	...	...	...	...
16703	Strawberry Nauts	PSV	2016	Adventure	0.00	0.00	0.01	0.00	NaN	NaN	no_us_rating	0.01
16707	Aiyoku no Eustia	PSV	2014	Misc	0.00	0.00	0.01	0.00	NaN	NaN	no_us_rating	0.01
16710	Samurai Warriors: Sanada Maru	PS3	2016	Action	0.00	0.00	0.01	0.00	NaN	NaN	no_us_rating	0.01
16712	Haitaka no Psychedelica	PSV	2016	Adventure	0.00	0.00	0.01	0.00	NaN	NaN	no_us_rating	0.01
16714	Winning Post 8 2016	PSV	2016	Simulation	0.00	0.00	0.01	0.00	NaN	NaN	no_us_rating	0.01

2897 rows × 12 columns

Выбор потенциально прибыльных платформ

Построим графики продаж для всех имеющихся платформ за актуальный период.

In [49]:
```
actual_period_platform_sales =\
actual_period_data.groupby(['platform', 'year_of_release']).agg({'total_sales':'sum'}).reset_index()
actual_period_platform_sales.head(10)
```

Out[49]:

	platform	year_of_release	total_sales
0	3DS	2012	51.76
1	3DS	2013	56.57
2	3DS	2014	43.76
3	3DS	2015	27.78
4	3DS	2016	15.14
5	DS	2012	11.67
6	DS	2013	1.54
7	PC	2012	23.45
8	PC	2013	12.66
9	PC	2014	13.28

In [50]:
```
grid = sns.FacetGrid(
    actual_period_platform_sales,
    col='platform',
    hue='platform',
    col_wrap=4,
    height=3,
    aspect=1.2
)
grid = grid.map(plt.plot, 'year_of_release', 'total_sales')
grid = grid.map(
    plt.fill_between,
    'year_of_release',
    'total_sales',
    alpha=0.2
).set_titles("{col_name}")
grid = grid.set_axis_labels("Год релиза", "Продажи")
plt.subplots_adjust(top=0.92)
grid = grid.fig.suptitle('Изменение продаж для платформы по годам')
plt.show()
```

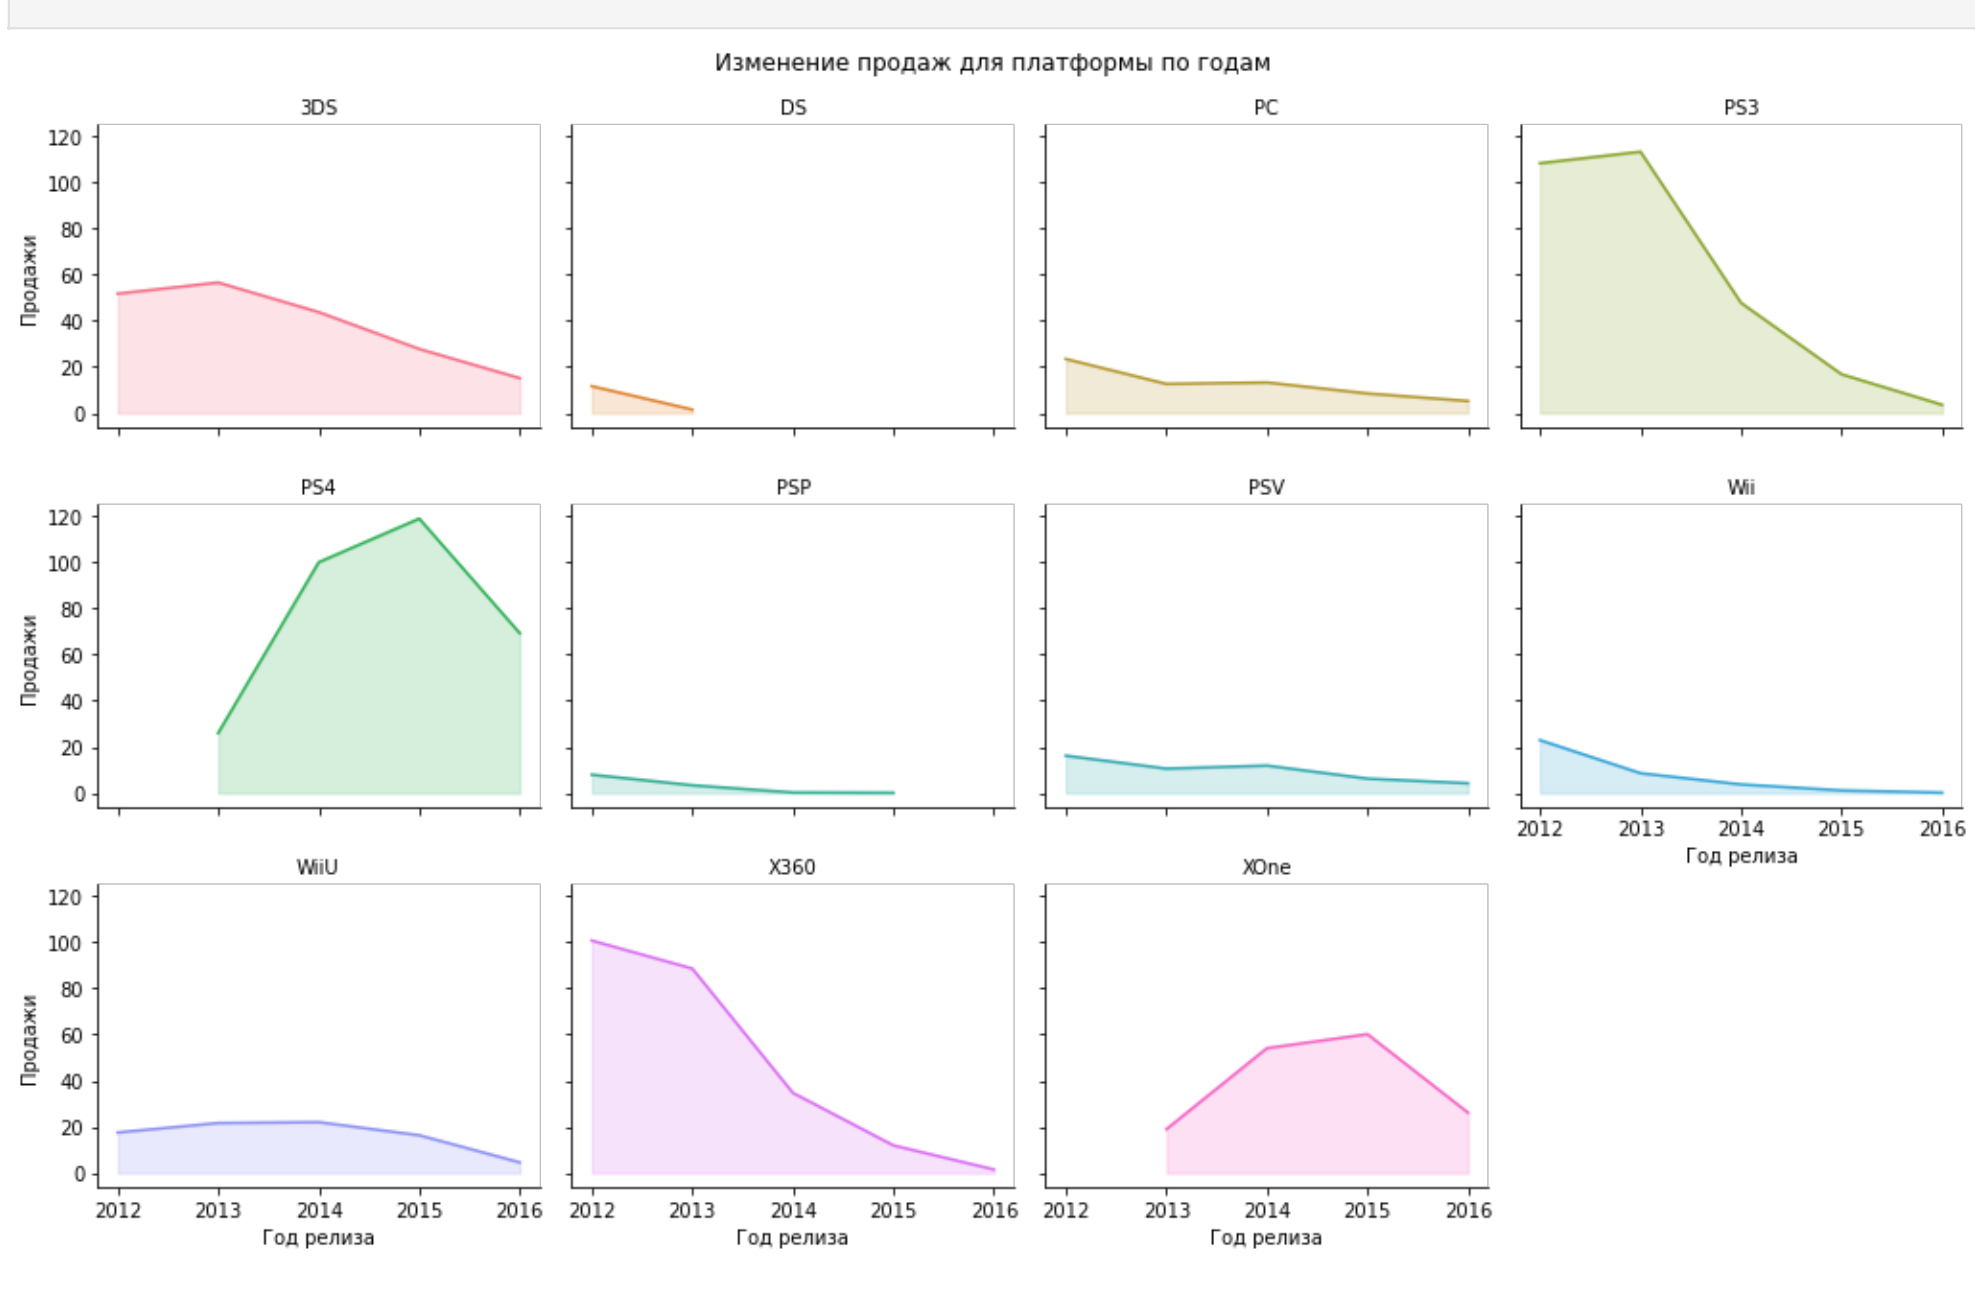

На основании приведенных графиков можно сделать вывод, что продажи игр на всех платформах падают.

In [51]:
```
plt.figure(figsize=(12,6))
plt.plot(
    actual_period_platform_sales.groupby('year_of_release').agg({'total_sales':'sum'}).index,
    actual_period_platform_sales.groupby('year_of_release').agg({'total_sales':'sum'})['total_sales'],
)
plt.xlabel('Год релиза')
plt.ylabel('Продажи')
plt.title('Изменение продаж по годам')
plt.show()
```

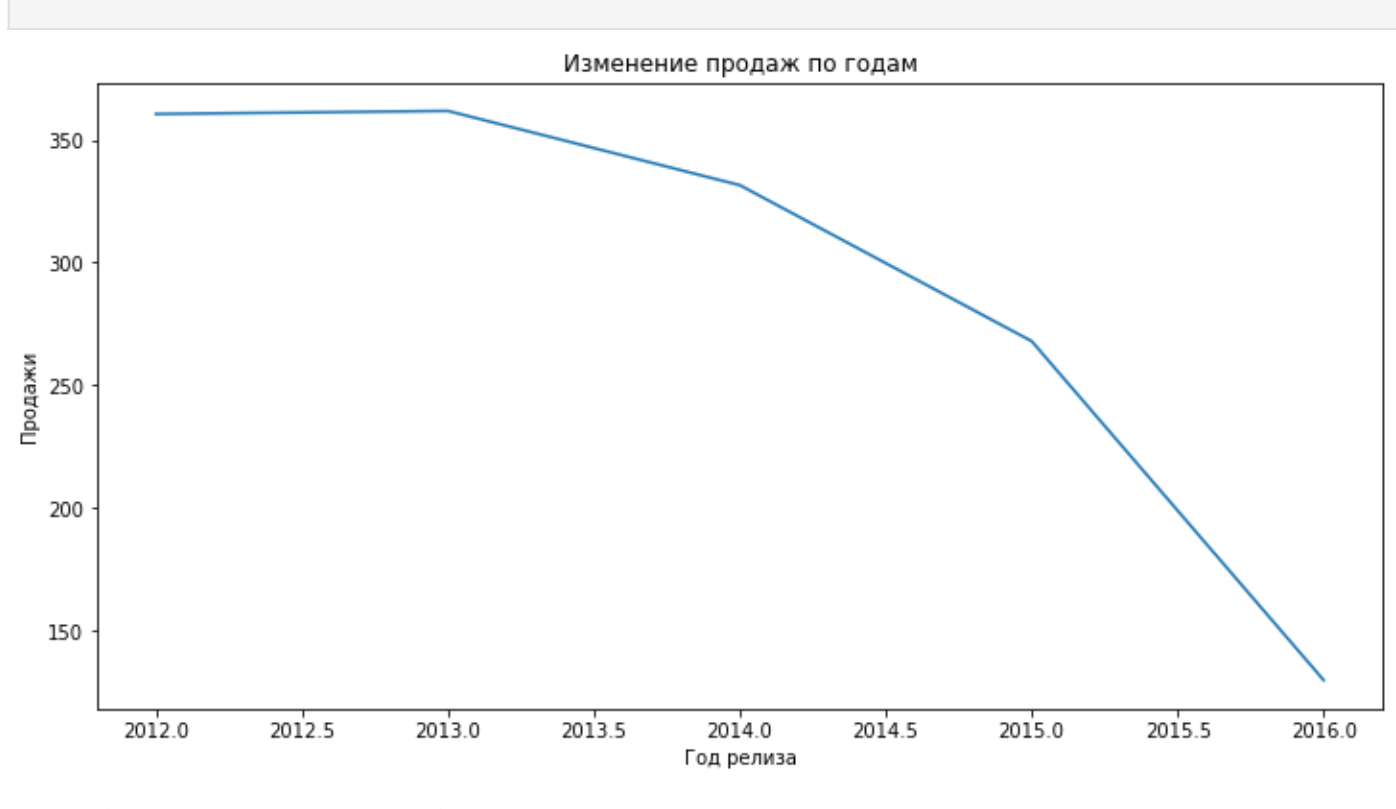

Это наблюдается и в целом на общих продажах всех игр. В связи с этим оценить тенденции не получается возможным.

Для того, чтобы увидеть какие-либо тренды, усредним продажи по отдельным платформам по общим продажам.

In [52]:
```
actual_period_platform_sales = actual_period_platform_sales.merge(
    actual_period_platform_sales.groupby('year_of_release').agg({'total_sales':'sum'}).reset_index(),
    on='year_of_release',
    how='left',
    suffixes=('_per_platform', '_yearly')
)
```

In [53]:
```
actual_period_platform_sales['relative_sales'] =\
actual_period_platform_sales['total_sales_per_platform'] / actual_period_platform_sales['total_sales_yearly'] * 100
actual_period_platform_sales.head(10)
```

Out[53]:

	platform	year_of_release	total_sales_per_platform	total_sales_yearly	relative_sales
0	3DS	2012	51.76	360.51	14.357438
1	3DS	2013	56.57	361.76	15.637439
2	3DS	2014	43.76	331.53	13.199409
3	3DS	2015	27.78	267.98	10.366445
4	3DS	2016	15.14	129.94	11.651531
5	DS	2012	11.67	360.51	3.237081
6	DS	2013	1.54	361.76	0.425697
7	PC	2012	23.45	360.51	6.504674
8	PC	2013	12.66	361.76	3.499558
9	PC	2014	13.28	331.53	4.005671

Теперь, определив относительные продажи игр, построим таблицу еще раз.

In [54]:
```
grid = sns.FacetGrid(
    actual_period_platform_sales,
    col='platform',
    hue='platform',
    col_wrap=4,
    height=3,
    aspect=1.2
)
grid = grid.map(plt.plot, 'year_of_release', 'relative_sales')
grid = grid.map(
    plt.fill_between,
    'year_of_release',
    'relative_sales',
    alpha=0.2
).set_titles("{col_name}")
grid = grid.set_axis_labels("Год релиза", "Относительные продажи, %")
plt.subplots_adjust(top=0.92)

plt.show()
```

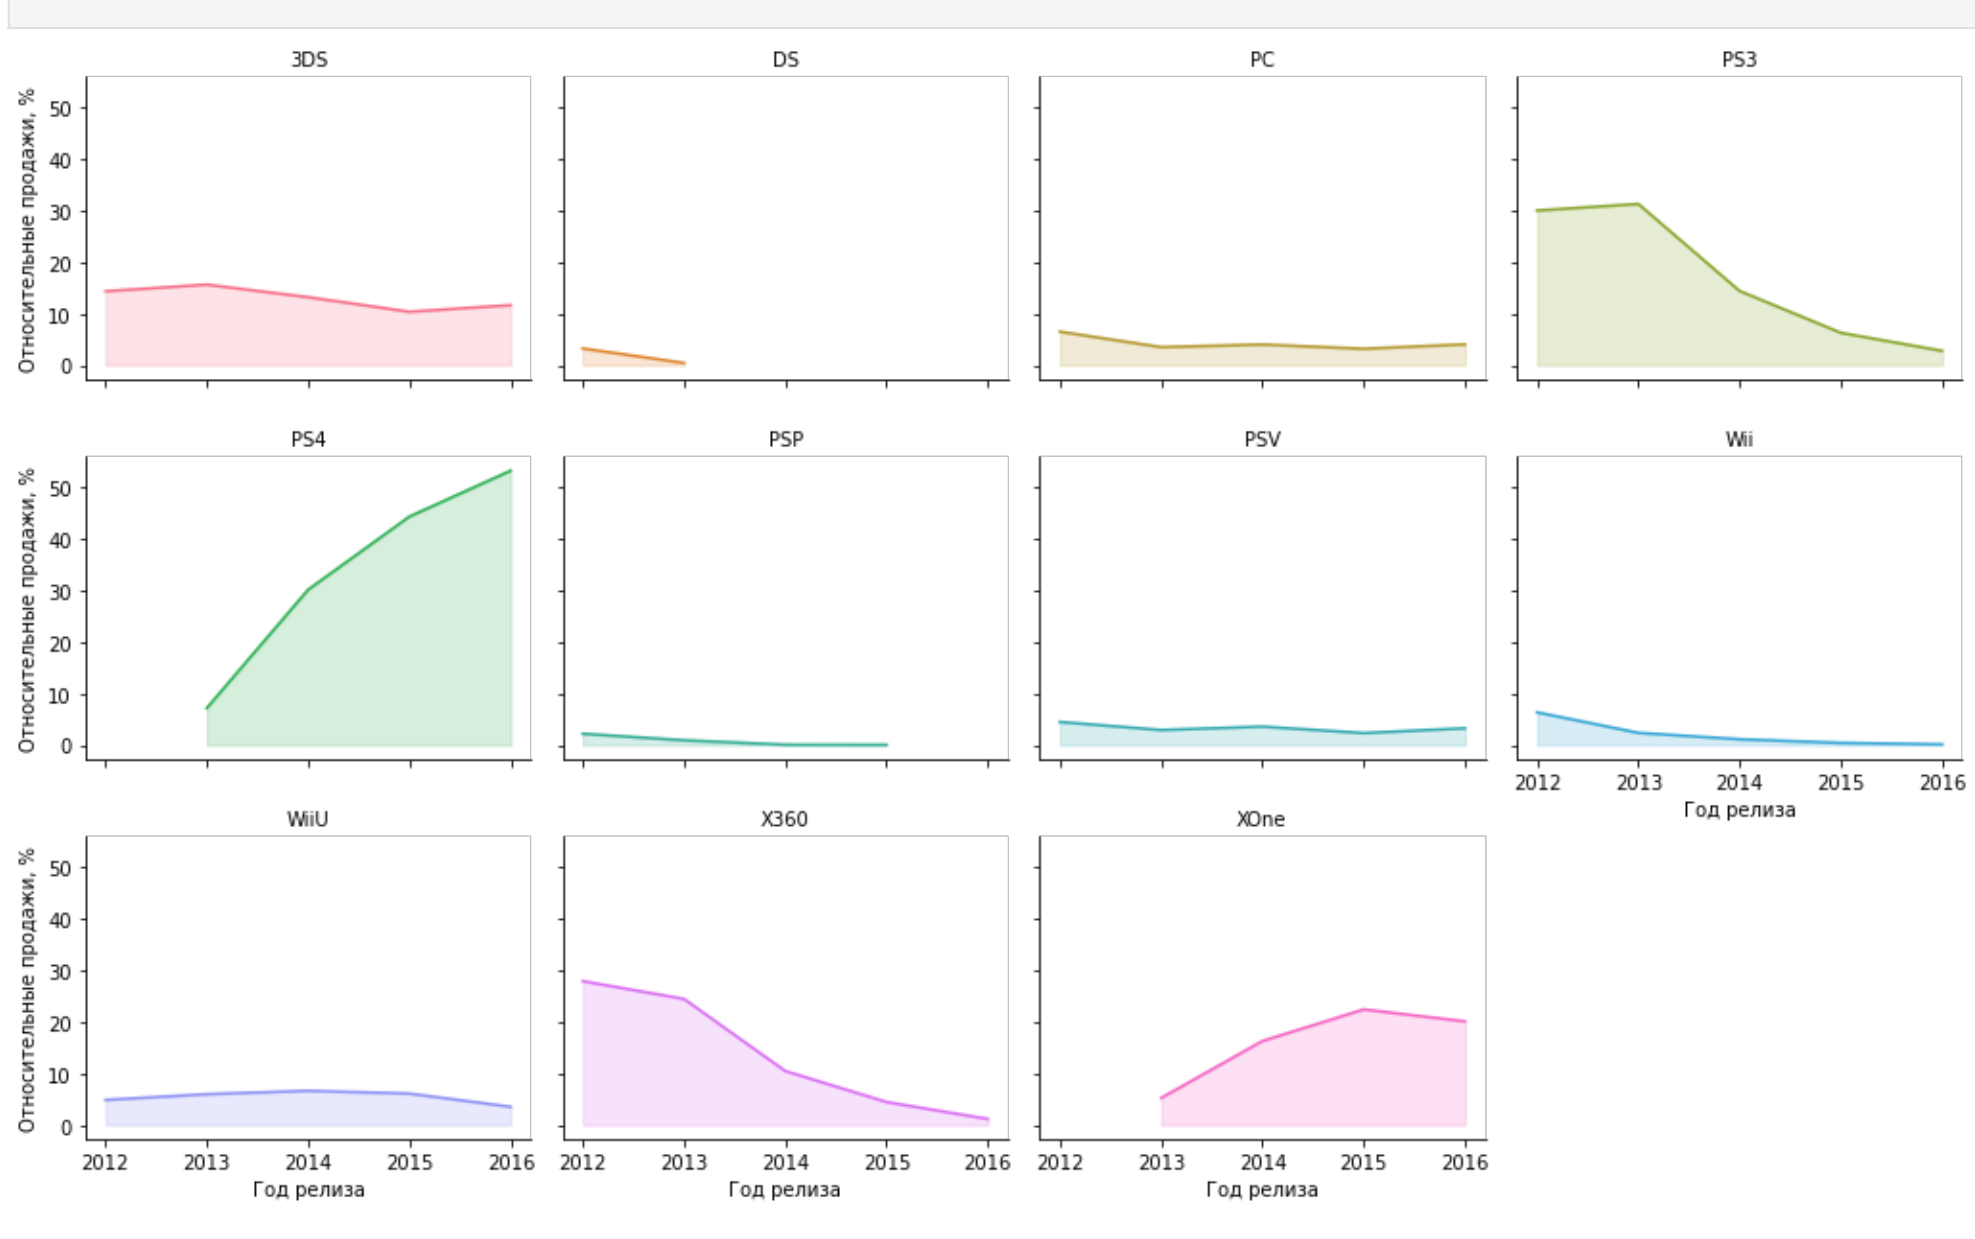

Теперь картина гораздо более ясная. Из всех представленных в акутальном периоде платформ, самой постоянной является ПК - часть продаж, приходящаяся на эту платформу немного растет, хоть и не превышает **5%**. Так же мы видим, что продажи для XBox One росли с 2013 года, и только в 2016 немного упали (**до 20%**). Продажи игр на PlayStation 4 в 2016 году превысили **50%** от всех проданных игр.

В целом, по имеющимся данным можно сделать следующий вывод:

- в последние годы PlayStaton 4 лидирует по продажам, и учитывая год запуска, еще несколько лет продажи будут расти;
- продажи на XBox One так же растут, но медленнее, с падением на несколько процентов в 2016 году;
- продажи на Nintendo 3DS стабильно достигают 10-15%, возможен дальнейший рост, учитывая специфику устройств от Nintendo и популярности платформы в Японии;
- продажи на ПК не опускаются ниже 7% и график продаж ровный;
- продажи на устаревающие платформы (*XBox 360, PlayStation 3, Wii*) падают и в ближайшие годы прекратятся;
- WiiU превышает показателей предшественницы, продажи меньше 10% и тенденция к падению

Потенциально прибыльными платформами в 2017 году можно считать новое поколение известных приставок (**XBox One, PlayStation 4**), **ПК**, а так же нишевые устройчтва - **PS Vita, Nintendo 3DS**).

Анализ продаж по платформам в актуальном периоде

Для анализа значений общих продаж по платформам, построим для каждой диаграмму размаха.

In [55]:
```
plt.figure(figsize=(12,6))

ax = sns.boxplot(
    x='platform',
    y='total_sales',
    data=actual_period_data,
)
ax.set_xlabel('Платформа')
ax.set_ylabel('Медианные продажи')
ax.set_title('Диаграммы размаха для продаж игр по каждой платформе')
plt.show()

plt.figure(figsize=(12,6))
ax = sns.boxplot(
    x='platform',
    y='total_sales',
    data=actual_period_data,
)
ax.set_xlabel('Платформа')
ax.set_ylabel('Суммарные продажи')
ax.set_ylim((0, 2))
plt.show()
```

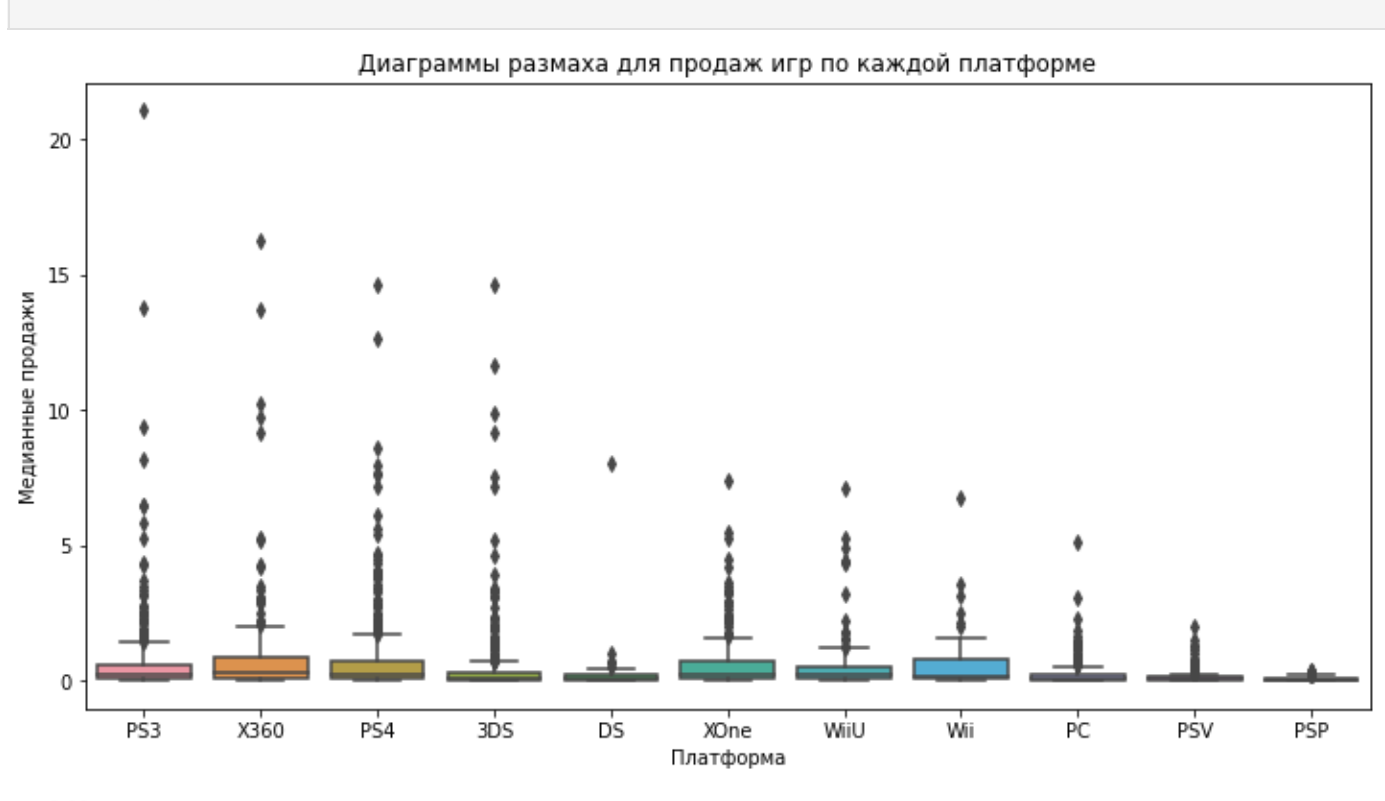

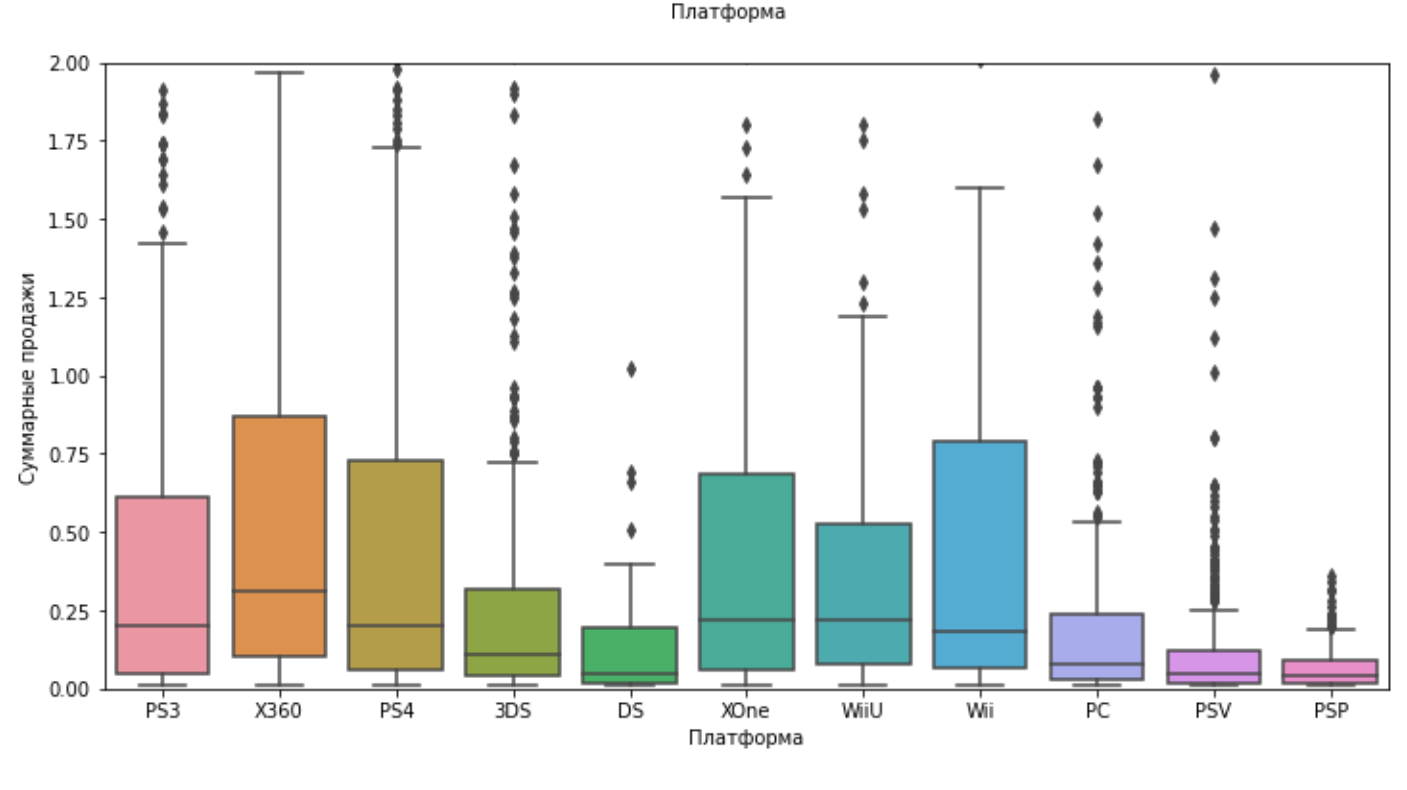

По данным диаграммам можно сделать несколько выводов:

- у всех платформ медианное значение продаж находится ближе к первому квартилю
- у всех платформ есть выбросы, данные значения расположены выше верхней границы значений
- чем популярнее платформа, тем больше выбросов в значениях продаж
- чем популярнее плафторма, тем больше границы межквартильного размаха
- наибольшие медианные продажи у Xbox 360, первый и третий квартили так же имеют наибольшие значения
- PlauStation 3, PlayStation 4, XBox One, Wii и WiiU имеют схожие значения медианных продаж

Влияние на продажи отзывов критиков и пользователей

Анализ самой популярной платформы

Определим самую популярную платформу за актуальный период.

In [56]:
```
actual_period_platform_sales.pivot_table(
    index='platform',
    values='total_sales_per_platform',
    aggfunc='sum'
).sort_values(by='total_sales_per_platform', ascending=False)
```

Out[56]:

	total_sales_per_platform
platform	
PS4	314.14
PS3	289.70
X360	237.52
3DS	195.01
XOne	159.32
WiiU	82.19
PC	63.16
PSV	49.18
Wii	36.60
DS	13.21
PSP	11.69

Такой платформой является PS4, на нее за весь акутальный период было куплено **314.14** млн копий. Построим диаграмму рассеяния для игр на данную платформу от отзывов критиков и пользователей.

In [57]:
```
fig, axs = plt.subplots(1, 2, figsize=(12, 6))

axs[0].plot(
    'critic_score',
    'total_sales',
    "",
    data=actual_period_data.loc[actual_period_data['platform'] == 'PS4'],
    linestyle='',
    marker='o',
    markersize=4,
    alpha=0.1,
    color="purple",

)
axs[0].set_title('Зависимость продаж от оценок критиков\nдля платформы PlayStation 4')
axs[0].set_xlabel('Оценки критиков')
axs[0].set_ylabel('Продажи')

axs[1].plot(
    'user_score',
    'total_sales',
    "",
    data=actual_period_data.loc[actual_period_data['platform'] == 'PS4'],
    linestyle='',
    marker='o',
    markersize=3,
    alpha=0.1,
    color="purple",
)

axs[1].set_title('Зависимость продаж от оценок пользователей\nдля платформы PlayStation 4')
axs[1].set_xlabel('Оценки пользователей')
axs[1].set_ylabel('Продажи')

plt.show()
```

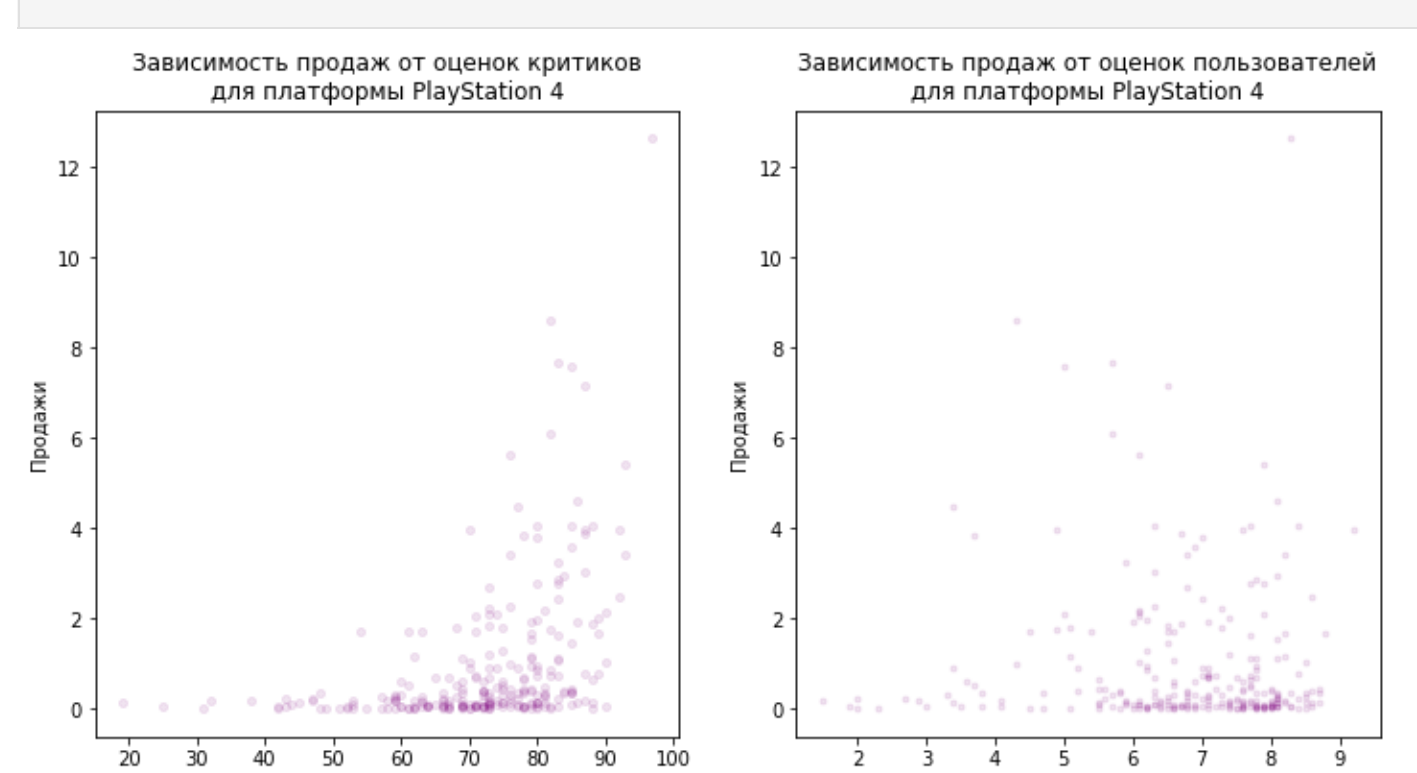

Как видно из графиков распределения, увеличение оценки как критиков, так и пользователей незначительно сказывается на продажах видеоигр, большинство продается на одном и том же уровне около 1 млн. копий. При этом, только у игр с отзывами критиков от 70 появляются игры с продажами, превышающими 5 млн проданных копий, и в целом, с ростом оценки распределение продаж становится шире. У распределения относительно отзывов пользователей такой картины не наблюдается. есть отдельные случаи больших продаж в независимости от оценок пользователей.

Рассчитаем коэффициент корреляции продаж от оценок критиков и пользователей.

In [58]:

```
print(
    'Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков:',
    (actual_period_data.loc[actual_period_data['platform'] == 'PS4']['total_sales'].corr(
        actual_period_data.loc[actual_period_data['platform'] == 'PS4']['critic_score'])
    )
)

print(
    'Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей:',
    (actual_period_data.loc[actual_period_data['platform'] == 'PS4']['total_sales'].corr(
        actual_period_data.loc[actual_period_data['platform'] == 'PS4']['user_score'])
    )
)
```

```
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков: 0.406567902061781
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей: -0.031957110204556376
```

Коэффициенты корреляции подтверждают выводы, сделанные по распределениям:

- в случае с оценками критиков, они имеют небольшое влияние на продажи, но малозаметное
- отзывы пользователей практически не влияют на увеличение или уменьшение продаж

Анализ всех платформ

Рассмотрим такой же график распределения продаж для всех платформ

In [59]:

```
for platform in list(
    actual_period_data.groupby('platform')['total_sales']
    .sum()
    .sort_values(ascending=False)
    .index[1:6]
):
    fig, axs = plt.subplots(1, 2, figsize=(12, 6))

    axs[0].plot(
        'critic_score',
        'total_sales',
        "",
        data=actual_period_data.loc[actual_period_data['platform']== platform],
        linestyle='',
        marker='o',
        markersize=4,
        alpha=0.1,
        color="purple",

    )
    axs[0].set_title(f'Зависимость продаж от оценок критиков для\nплатформы: {platform}')
    axs[0].set_xlabel('Оценки критиков')
    axs[0].set_ylabel('Продажи')

    axs[1].plot(
        'user_score',
        'total_sales',
        "",
        data=actual_period_data.loc[actual_period_data['platform']== platform],
        linestyle='',
        marker='o',
        markersize=3,
        alpha=0.1,
        color="purple",
    )

    axs[1].set_title(f'Зависимость продаж от оценок пользователей для\nплатформы: {platform}')
    axs[1].set_xlabel('Оценки пользователей')
    axs[1].set_ylabel('Продажи')

    plt.show()

    print(
    'Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков:',
    (actual_period_data.loc[actual_period_data['platform'] == platform]['total_sales'].corr(
        actual_period_data.loc[actual_period_data['platform'] == platform]['critic_score']))
    )

    print(
    'Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей:',
    (actual_period_data.loc[actual_period_data['platform'] == platform]['total_sales'].corr(
        actual_period_data.loc[actual_period_data['platform'] == platform]['user_score']))
    )
```

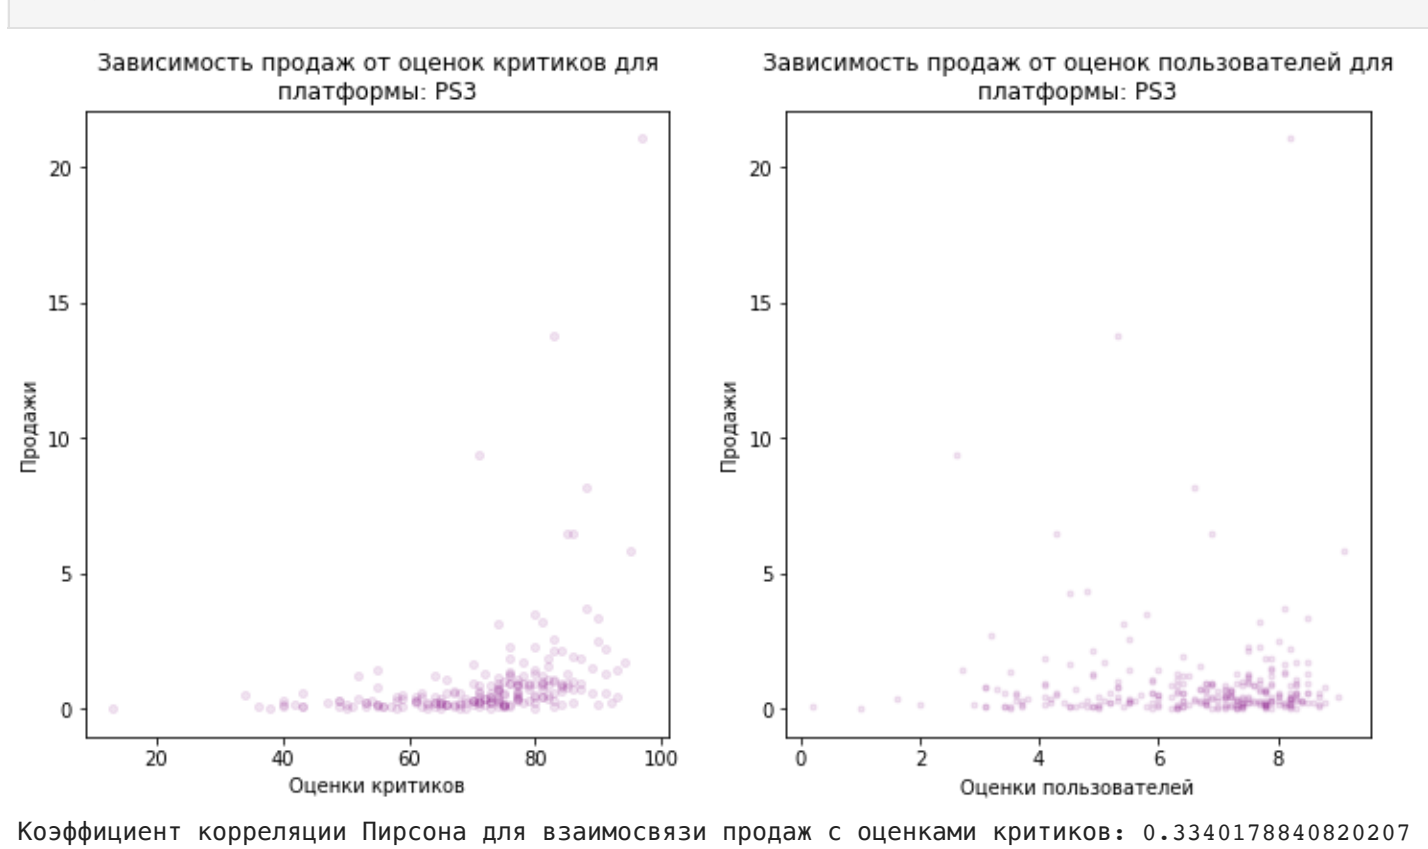

```
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков: 0.3340178840820207
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей: -0.0061096047528258705
```

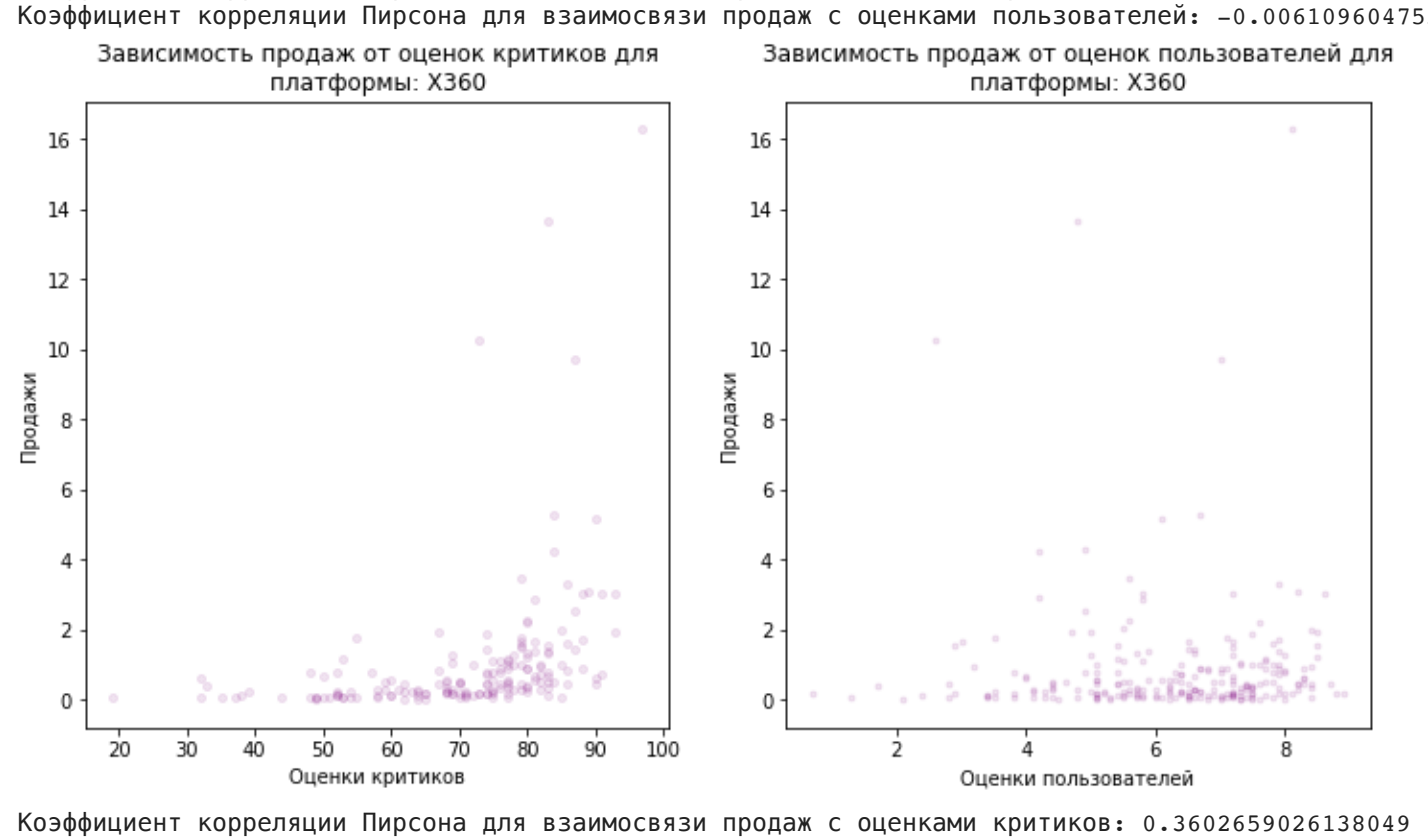

```
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков: 0.3602659026138049
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей: 0.006314938203566999
```

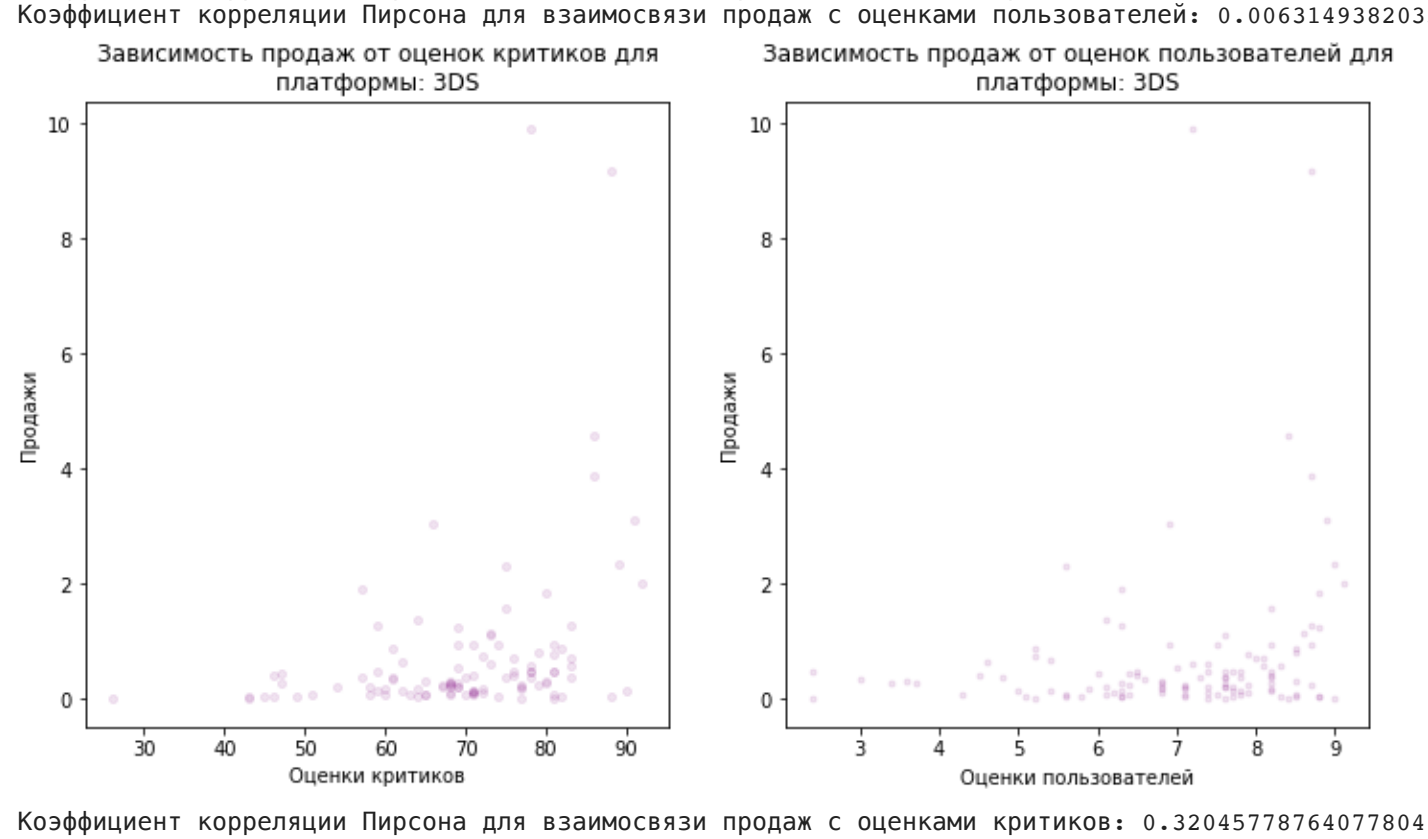

```
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков: 0.32045778764077804
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей: 0.19814963960883375
```

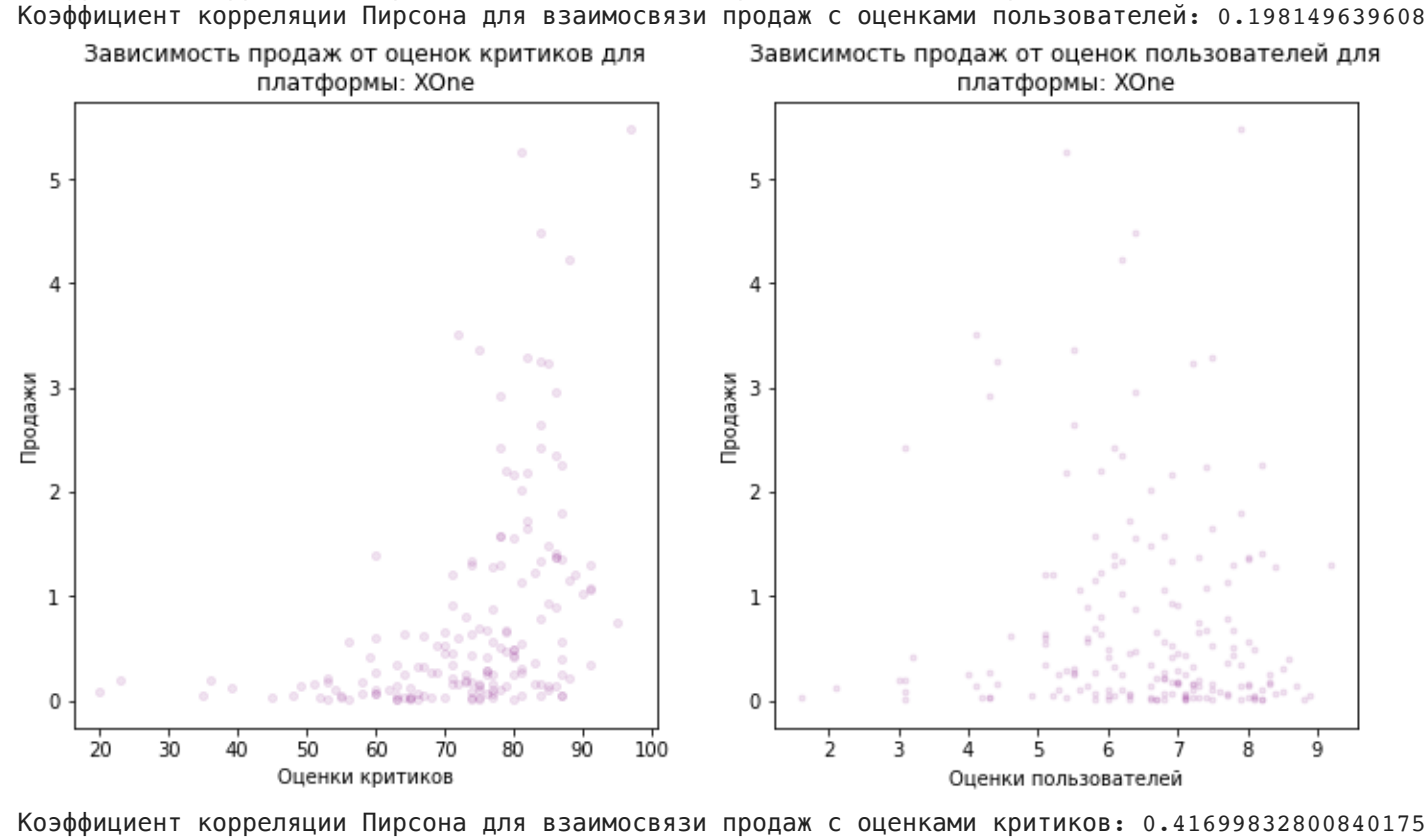

```
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков: 0.41699832800840175
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей: -0.06892505328279412
```

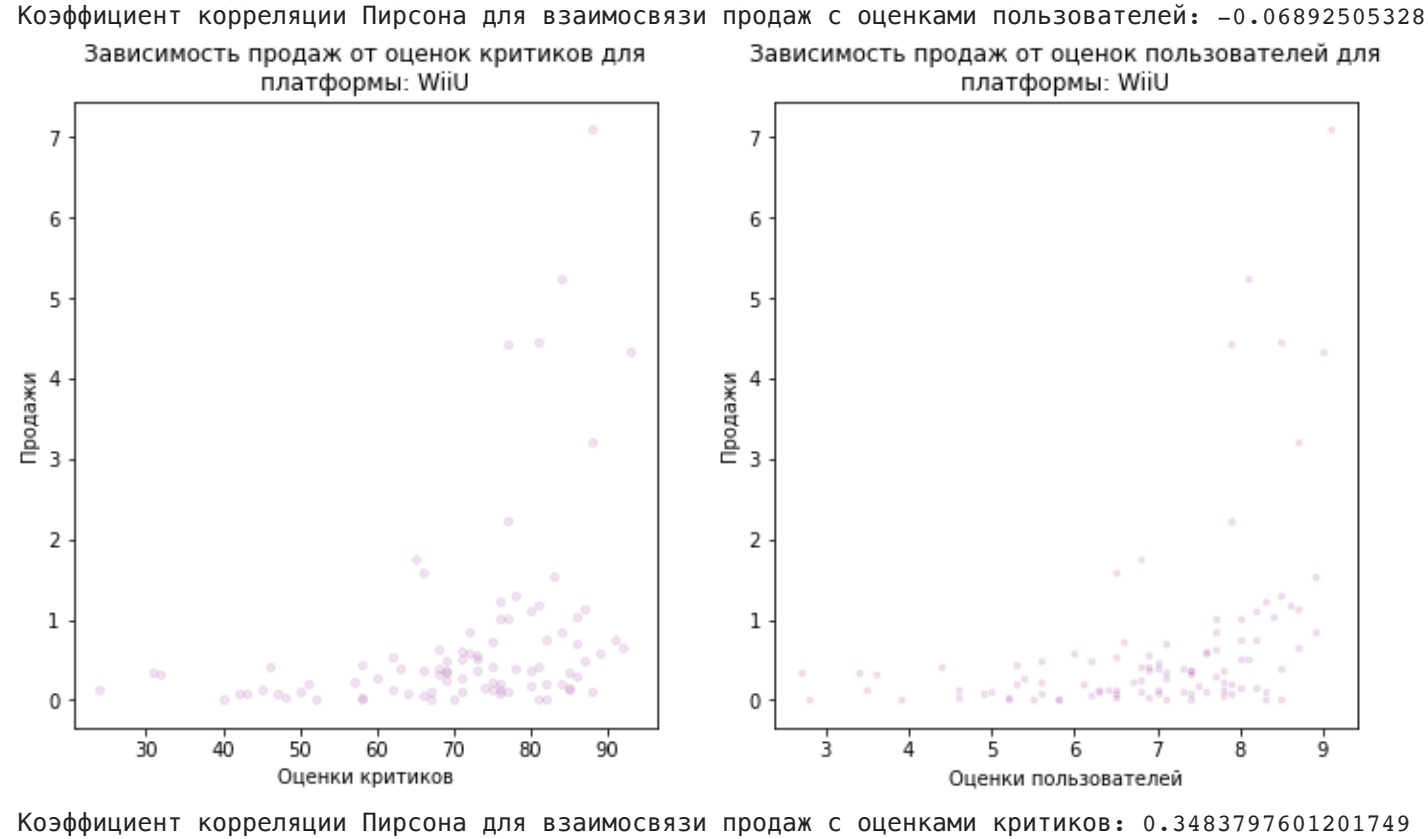

```
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками критиков: 0.3483797601201749
Коэффициент корреляции Пирсона для взаимосвязи продаж с оценками пользователей: 0.4002190202148617
```

На большинстве платформ картина идентичная. Оценки критиков влияют сильнее, чем оценки пользователей, но это влияние достаточно мало. Только среди игр на японские платформы (Nintendo 3DS и Nintendo WiiU) коэффициент корреляции продаж игр с отзывами пользователей выше. При этом, во всех случаях, он не превышает 0.5, так что доводов говорить о сильной взаимосвязи исходя из этих графиков нельзя.

Объяснить это можно следующим: критики получают игры гораздо раньше пользователей, и во многих случаях, если нет моратория на публикацию рецензий, сами отзывы выходят раньше. В связи с этим, пользователи отталкиваются от этих оценок при принятии решения о покупке. Тем временем, пользователи могут оценить игру уже после ее выхода, и соответственно, покупки пользователями (не берем во внимание спланированные компании по накручиванию негативного/позитивного рейтинга). Поэтому в случае с оценками пользователей, если игра ожидаемая, но финальная версия плохого качества, то пользователи сначала купят ее, поднимут продажи, и лишь затем анпишут отзыв с низкой оценкой, что гораздо меньше повлияет на дальнейшие продажи этой игры.

Распределение жанров и их прибыльность

Сгруппируем данные за актуальный период по жанрам для подробного анализа влияния жанра на продажи и отсортируем их по количеству игр в каждом жанре, и по количеству продаж и построим круговые диаграммы по количеству игр каждого жанра и количеству продаж каждого жанра.

In [60]:

```
actual_period_genre_data = actual_period_data.groupby('genre').agg({'total_sales':['count', 'median']})
actual_period_genre_data = actual_period_genre_data.reset_index()
actual_period_genre_data.columns = ['genre', 'count', 'median_sales']

actual_period_genre_data.sort_values(by='count', ascending = False)
```

Out[60]:

	genre	count	median_sales
0	Action	1040	0.120
7	Role-Playing	370	0.140
1	Adventure	302	0.030
10	Sports	267	0.240
8	Shooter	237	0.430
3	Misc	193	0.120
6	Racing	115	0.140
2	Fighting	109	0.130
4	Platform	85	0.210
9	Simulation	80	0.120
11	Strategy	71	0.080
5	Puzzle	28	0.045

In [61]:

```
plt.figure(figsize=(10,10))

ax = actual_period_genre_data['count'].plot(
    kind='pie',
    labels=actual_period_genre_data['genre'].unique(),
    autopct='%1.1f%%',
    pctdistance=0.9,
    colors=mcolors.TABLEAU_COLORS
)

ax.set_ylabel('')
ax.set_title('Количество выпущенных игр\n по жанрам')

plt.show()
```

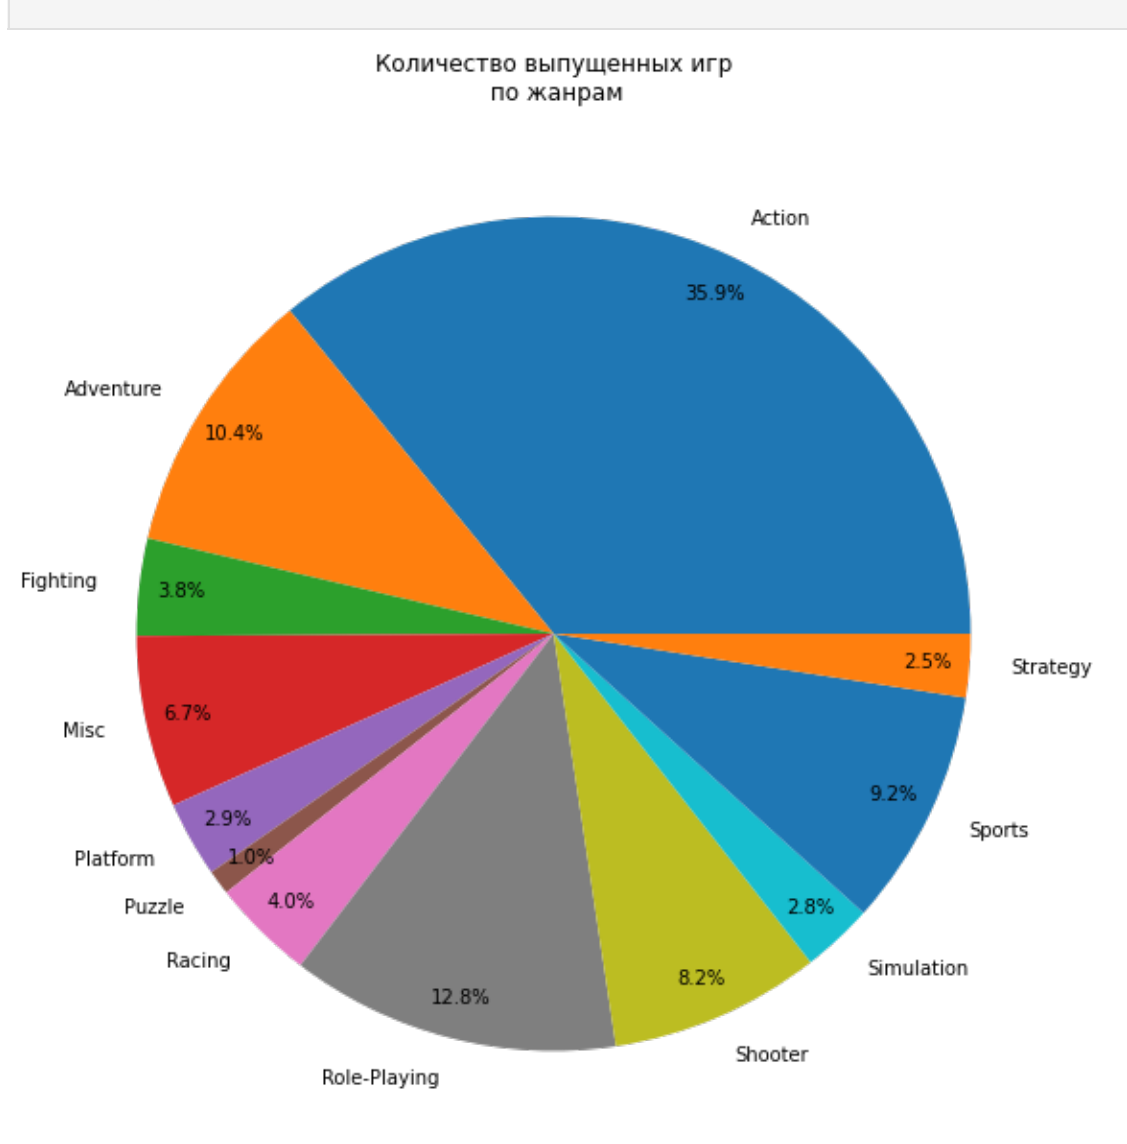

За актуальный период продавались игры в 12 жанрах. Самый частый жанр игр : **Action** (1040 игр). На втором месте ролевые игры (370). Третье место по количеству занимает жанр **Приключенческих игр** (302 наименования) . На четвертом месте - **Спортивные игры** (267 игры). Замыкает топ-5 жанров по количеству выпускаемых игр жанр **Шутеров** - 237 игры.

Рассмотрим, как обстоят дела с продажами.

In [62]:

```
plt.figure(figsize=(12,6))
ax = sns.boxplot(
    x='genre',
    y='total_sales',
    data=actual_period_data,
)
ax.set_title('Продажи игр по жанрам\nв актуальном периоде')
ax.set_xlabel('Жанр')
ax.set_ylabel('Продажи')
plt.show()

plt.figure(figsize=(12,6))
ax = sns.boxplot(
    x='genre',
    y='total_sales',
    data=actual_period_data,
)
ax.set_title('Продажи игр по жанрам\nв актуальном периоде')
ax.set_xlabel('Жанр')
ax.set_ylabel('Продажи')
ax.set_ylim((0,3.5))
plt.show()

actual_period_genre_data.sort_values(by='median_sales', ascending = False)
```

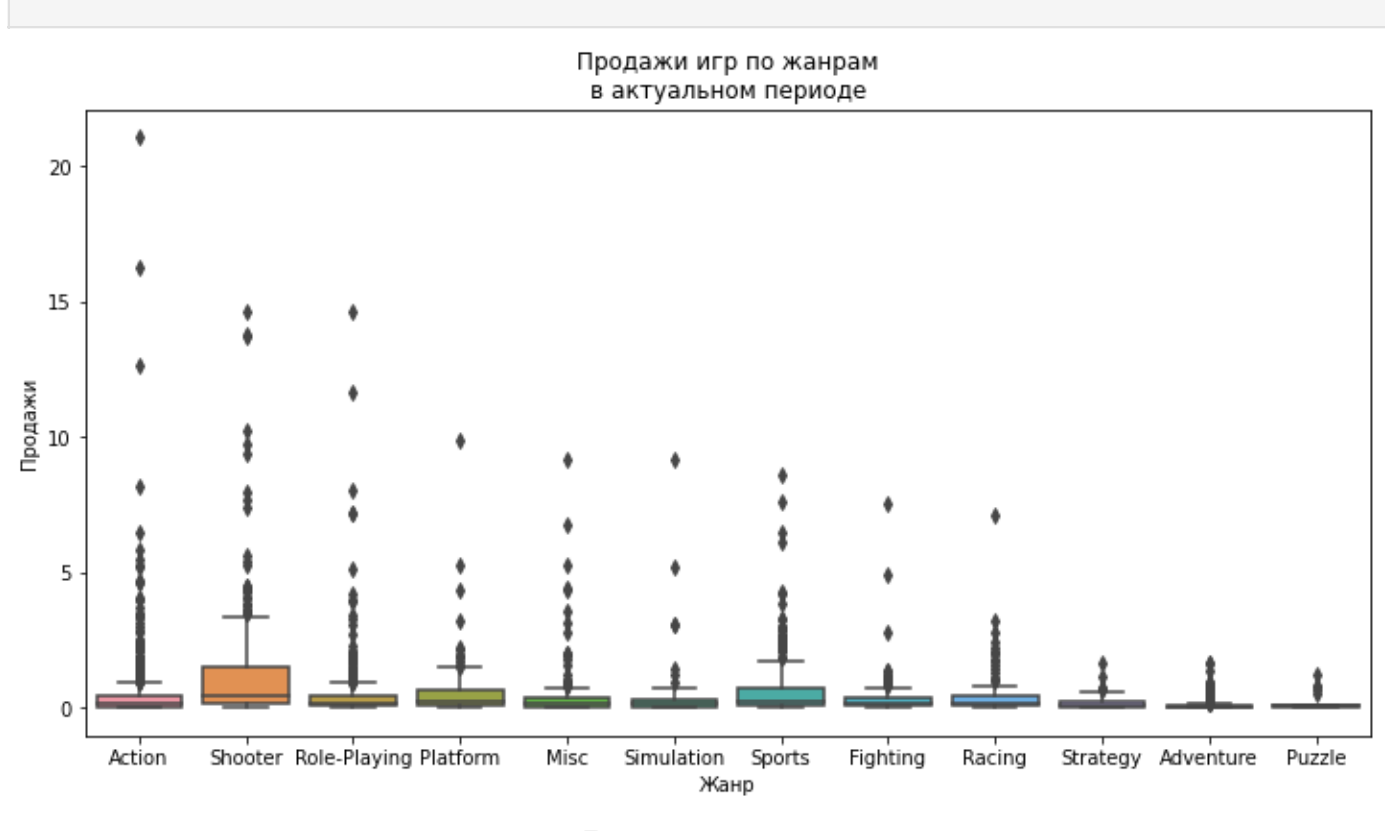

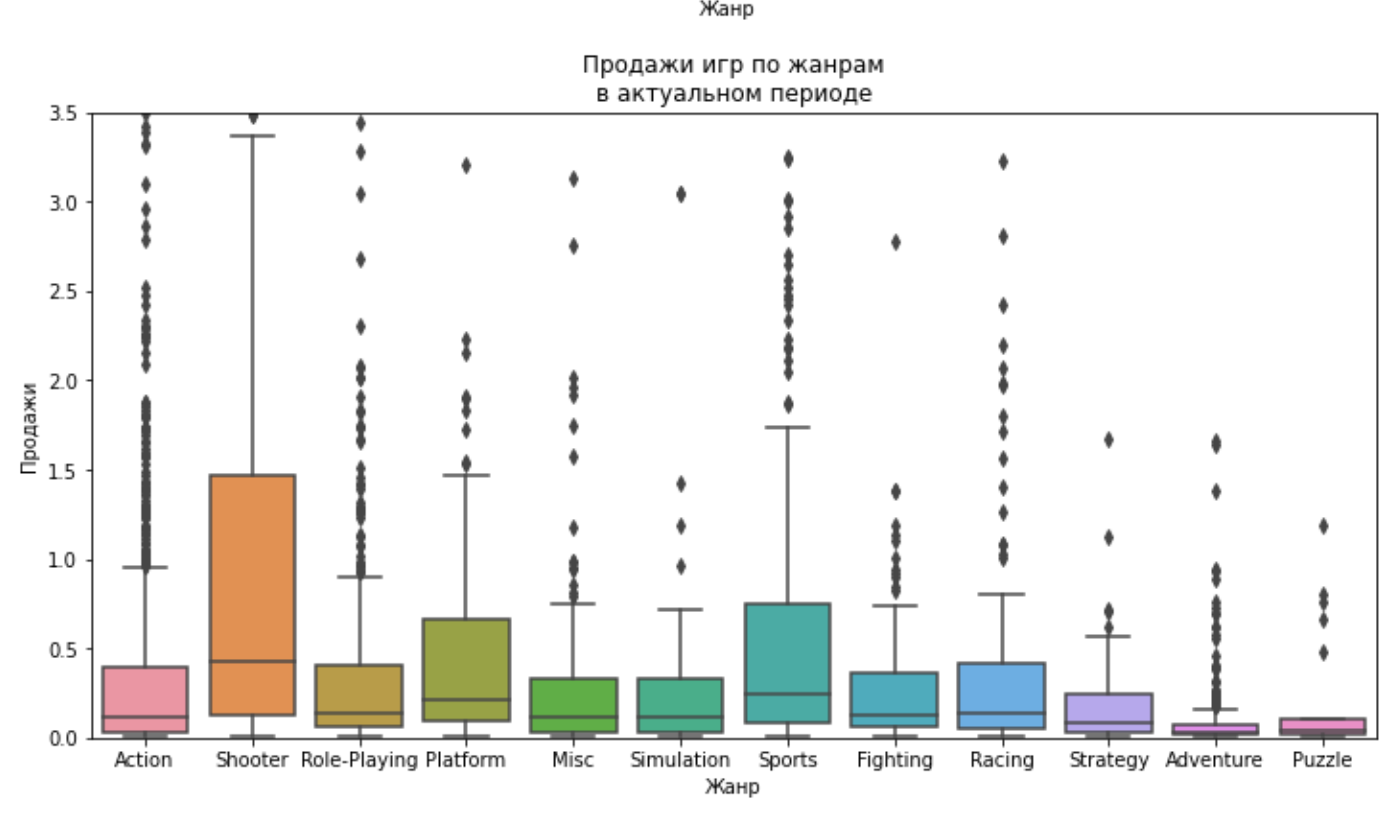

Out[62]:

	genre	count	median_sales
8	Shooter	237	0.430
10	Sports	267	0.240
4	Platform	85	0.210
7	Role-Playing	370	0.140
6	Racing	115	0.140
2	Fighting	109	0.130
0	Action	1040	0.120
3	Misc	193	0.120
9	Simulation	80	0.120
11	Strategy	71	0.080
5	Puzzle	28	0.045
1	Adventure	302	0.030

Жанром с самыми высокими медианными продажами является жанр **Шутеров**. При этом, у данного жанра самый широкий межквартильный размах. На втором месте жанр **спортивных игр**, кроме того, близко к нему находится жанр **платформеров**. 4-5 места занимают **ролевые игры** и **гоночные**. Значения медианных продаж у них одинаковы, а диаграммы размаха практически одинаковы.

Портрет пользователей различных регионов

Анализ популярности платформ по регионам

Рассмотрим суммарные продажи игр на каждую платформу в акутальном периоде по регионам.

In [63]:

```
actual_period_region_data_pivot =\
actual_period_data.pivot_table(
    values=['na_sales', 'eu_sales', 'jp_sales', 'other_sales'],
    index=['platform'],
    aggfunc='sum',
).reset_index()

actual_period_region_data_pivot
```

Out[63]:

	platform	eu_sales	jp_sales	na_sales	other_sales
0	3DS	42.83	87.79	55.49	8.90
1	DS	3.78	3.72	4.93	0.78
2	PC	38.13	0.00	19.20	5.83
3	PS3	107.26	35.29	103.74	43.41
4	PS4	141.09	15.96	108.74	48.35
5	PSP	0.52	10.71	0.23	0.23
6	PSV	11.36	21.04	10.98	5.80
7	Wii	12.34	3.39	18.14	2.73
8	WiiU	25.13	13.01	38.10	5.95
9	X360	74.89	1.57	140.57	20.49
10	XOne	51.59	0.34	93.12	14.27

Теперь построим графики для каждого региона, где будут указаны доли продажи на 5 наиболее популярных платформ.

In [64]:

```
fig, axs = plt.subplots(1, 4, figsize=(20, 5))
i = 0
titles=['Северная Америка', 'Европа', 'Япония', 'Другие страны']
colors=[]
for region in ['na_sales', 'eu_sales', 'jp_sales', 'other_sales']:
    top_platforms = actual_period_region_data_pivot.nlargest(5, region)['platform'].unique()
    other_platforms_data = actual_period_region_data_pivot[~actual_period_region_data_pivot['platform'].isin(top_platforms)]
    other_platforms_sales = other_platforms_data[region].sum()
    other_platforms_data = pd.DataFrame([{'platform': 'other_platform', region: other_platforms_sales}])

    platform_data = pd.concat(
        [actual_period_region_data_pivot[actual_period_region_data_pivot['platform'].isin(top_platforms)],
         other_platforms_data]
    )

    platform_data[region].plot(
        kind='pie',
        xlabel='Платформа',
        ylabel= '',
        ax =axs[i],
        labels=platform_data['platform'].unique(),
        autopct='%1.1f%%'
    )
    axs[i].set_title(titles[i])
    i += 1
    fig.suptitle('Продажи по платформам в разных регионах', fontsize=16, y=1.05)


plt.show()
```

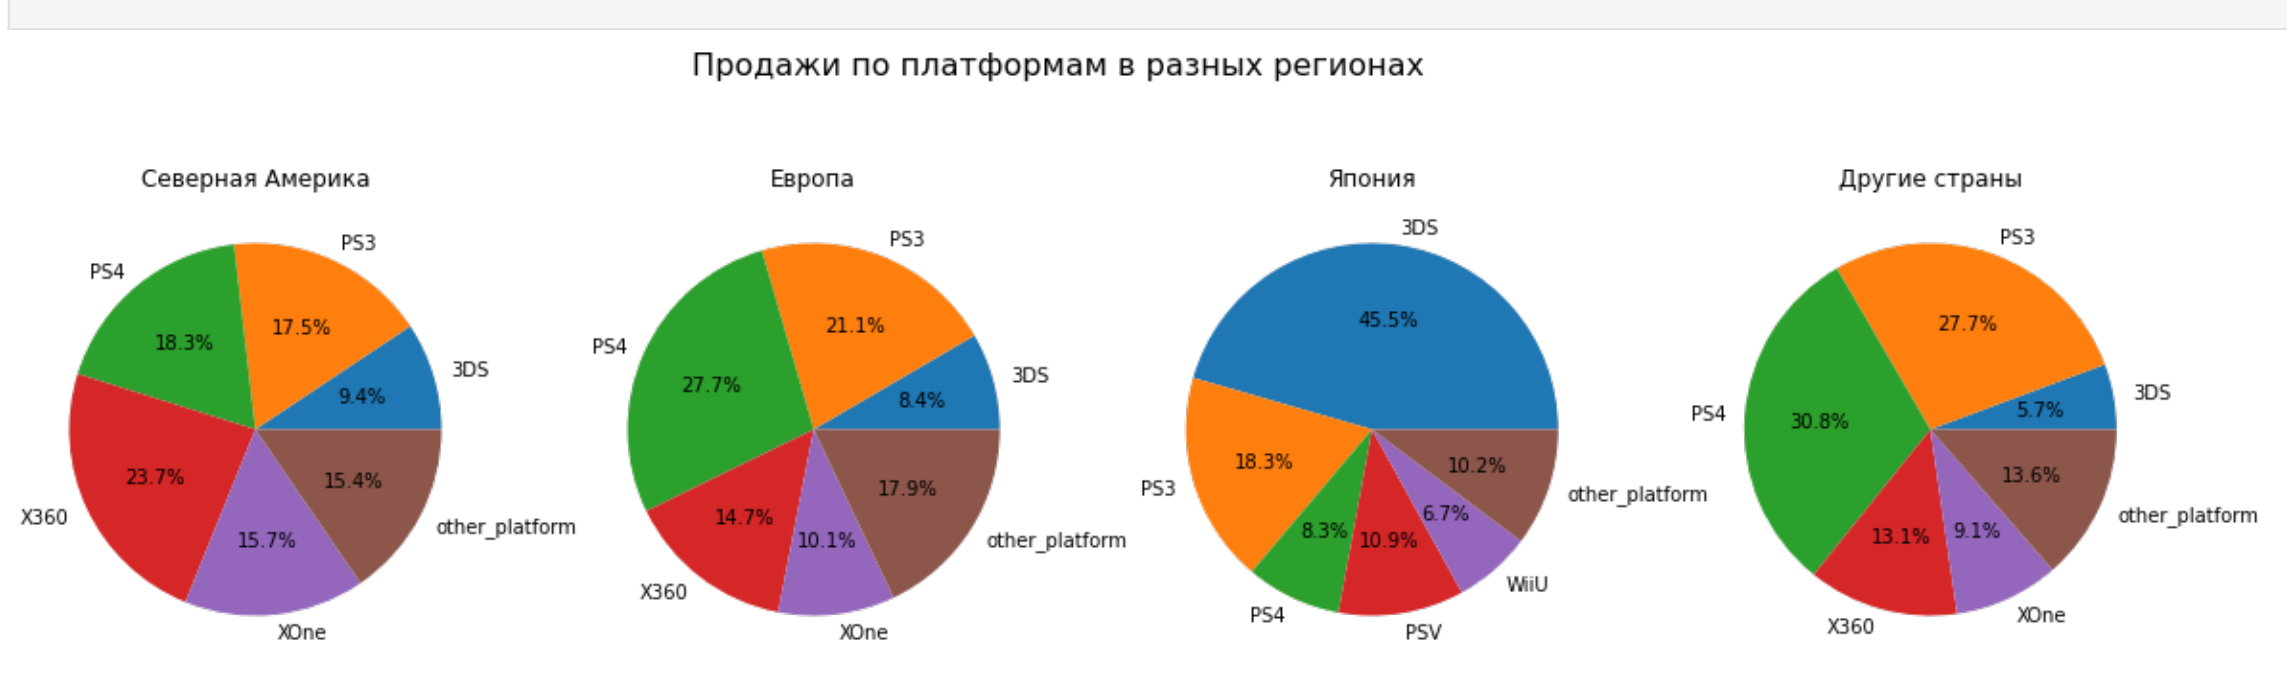

Как мы видим, в различных регионах картина сильно различается.

- В **Северной Америке** самой популярной платформой за актуальный период является **XBox 360**, на него приходится более почти 25% процентов всех продаж в регионе.
- В **Европе** самой популярной является платформа **PlayStation 4**, на нее приходится почти 28% продаж. Д
- В **Японии** самой популярной является Nintendo 3DS - ~45% от всех продаж в регионе.
- В **остальных странах** самой популярной платформой является **PlayStation 4**, на нее приходится более 30% всех продаж.

Анализ популярности жанров по регионам

Рассмотрим суммарные продажи игр каждого жанра в акутальном периоде по регионам.

In [65]:

```
actual_period_region_genre_data_pivot =\
actual_period_data.pivot_table(
    values=['na_sales', 'eu_sales', 'jp_sales', 'other_sales'],
    index=['genre'],
    aggfunc='sum',
).reset_index()

actual_period_region_genre_data_pivot
```

Out[65]:

	genre	eu_sales	jp_sales	na_sales	other_sales
0	Action	161.45	52.80	180.09	51.72
1	Adventure	9.46	8.24	8.92	2.81
2	Fighting	10.79	9.44	19.79	4.47
3	Misc	26.32	13.10	38.19	7.67
4	Platform	21.41	8.63	25.38	5.58
5	Puzzle	1.40	2.14	1.13	0.22
6	Racing	27.29	2.50	17.22	6.49
7	Role-Playing	48.53	65.44	64.00	14.83
8	Shooter	113.47	9.23	144.79	37.26
9	Simulation	14.55	10.41	7.97	2.19
10	Sports	69.08	8.01	81.53	22.44
11	Strategy	5.17	2.88	4.23	1.06

In [66]:

```
fig, axs = plt.subplots(1, 4, figsize=(20, 5))
i = 0
titles=['Северная Америка', 'Европа', 'Япония', 'Другие страны']
colors=[]
for region in ['na_sales', 'eu_sales', 'jp_sales', 'other_sales']:
    top_genres = actual_period_region_genre_data_pivot.nlargest(5, region)['genre'].unique()
    other_genres_data = actual_period_region_genre_data_pivot[~actual_period_region_genre_data_pivot['genre'].isin(top_genres)]
    other_genres_sales = other_genres_data[region].sum()
    other_genres_data = pd.DataFrame([{'genre': 'other_genre', region: other_platforms_sales}])

    genre_data = pd.concat(
        [actual_period_region_genre_data_pivot[actual_period_region_genre_data_pivot['genre'].isin(top_genres)],
         other_genres_data]
    )

    genre_data[region].plot(
        kind='pie',
        xlabel='Жанр',
        ax =axs[i],
        ylabel='',
        labels=genre_data['genre'].unique(),
        autopct='%1.1f%%'
    )
    axs[i].set_title(titles[i])
    i += 1
    fig.suptitle('Продажи по жанрам в разных регионах', fontsize=16, y=1.05)

plt.show()
```

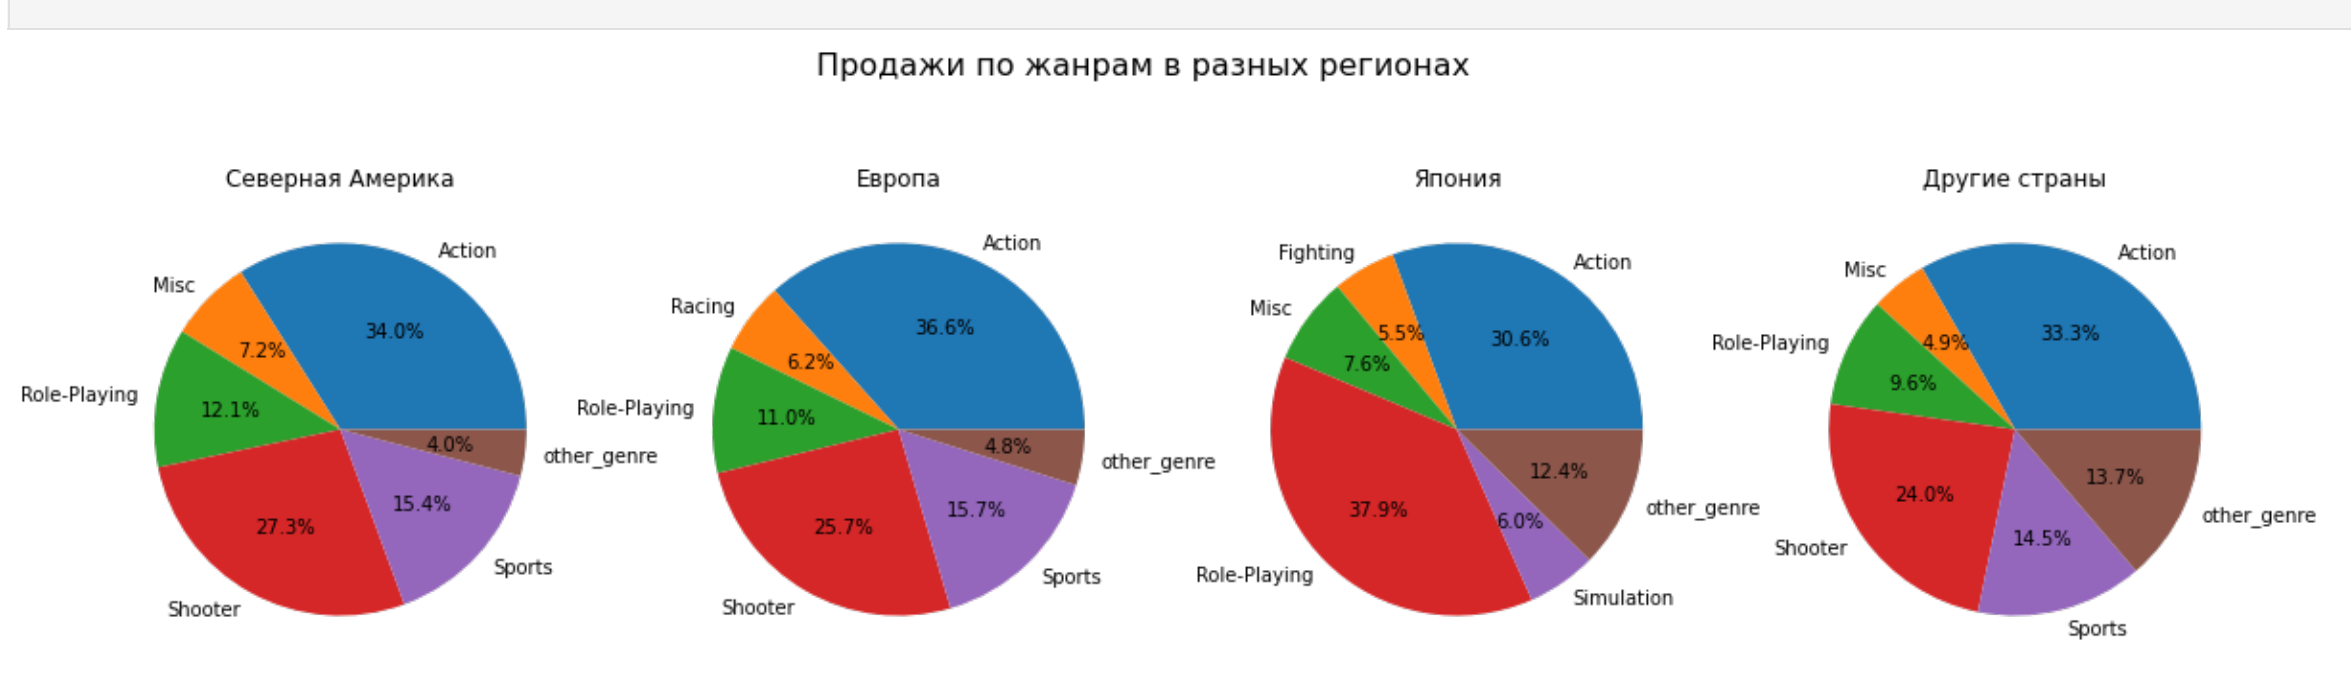

В случае с жанрами, картина более однородная: во всех регионах за актуальный период доля **Экшн-игр** превышает 30%, а в случае с продажами в Европе, первышает практически 35%. При этом в Японии на первом месте жанр **Ролевых игр** (почти 38% всех продаж). *Это неудивительно, поскольку в данном регионе РПГ, а особенно поджанр jRPG (т.е. японские РПГ), очень популярен.*

Распределение продаж по жанрам в **Северной Америке и Европе** схоже и по остальным играм, кроме жанра, замыкающего топ-5: на пятом месте в случае Северной Амрики находятся игры другого жанра, в Европе - гонки (~7%).

Влияние возрастного рейтинга ESRB на продажи в отдельном регионе

Для оценки влияния рейтинга ESRB на продажи внутри регионов, построим такие же графики зависимостей в зависимости от выставленного игре рейтинга.

Кроме того, распишем, что означает каждый рейтинг:

- **«EC» («Early childhood») — «Для детей младшего возраста»**: Игра подходит для детей от 3 лет и не содержит материалов, которые родители могли бы счесть неподходящими. Продукты, получившие данный рейтинг, изначально разрабатываются для детей и обычно представляют собой развивающие игры.
- **«E» («Everyone») — «Для всех»**: Содержание вполне подходит для всех возрастов. Такие игры могут понравиться и взрослым. Игры с этим рейтингом могут содержать минимальное насилие, в основном «мультяшного» характера.
- **«E10+» («Everyone 10 and older») — «Для всех от 10 лет и старше»**: Проекты с данным рейтингом могут содержать больше мультипликационного или мягкого насилия, или несколько откровенные сцены, или минимальное количество крови.
- **«T» («Teen») — «Подросткам»**: Игра подходит для лиц от 13 лет. Проекты из данной категории могут содержать насилие, непристойные сцены, грубый юмор, в меру откровенное сексуальное содержимое, кровь или нечастое использование ненормативной лексики.
- **«M» («Mature») — «Для взрослых»**: Материалы игры не подходят для лиц младше 17 лет. Проекты с данным рейтингом могут содержать жестокое насилие, большое количество крови с расчленением, непристойные сексуальные сцены или грубую ненормативную лексику.
- **«AO» («Adults Only 18+») — «Только для взрослых»**: Содержание игры только для взрослых старше 18 лет. Продукты из данной категории могут содержать длительные сцены жестокого насилия и/или очень откровенное сексуальное содержимое.
- **«RP» («Rating Pending») — «Рейтинг ожидается»**: Продукт был отправлен в ESRB и ожидает присвоения рейтинга. Данный логотип используется только на рекламных презентациях и в демо-версиях игр до официальной даты выпуска в продажу.

In [67]:

```
actual_period_region_raiting_data_pivot =\
actual_period_data.pivot_table(
    values=['na_sales', 'eu_sales', 'jp_sales', 'other_sales'],
    index=['rating'],
    aggfunc='sum'
)

actual_period_region_raiting_data_pivot
```

Out[67]:

	eu_sales	jp_sales	na_sales	other_sales
rating				
E	108.63	28.16	117.03	31.25
E10+	56.90	7.44	79.55	17.17
M	198.75	19.83	238.09	65.34
T	53.78	19.75	69.28	18.98
no_us_rating	18.20	80.93	0.00	1.96

Построим графики для каждого региона.

In [68]:

```
fig, axs = plt.subplots(1, 4, figsize=(25, 7))
i = 0
titles=['Северная Америка', 'Европа', 'Япония', 'Другие страны']
colors=[]
for region in ['na_sales', 'eu_sales', 'jp_sales', 'other_sales']:
    (100*(actual_period_region_raiting_data_pivot[region]/actual_period_region_raiting_data_pivot[region].sum())).sort_values(ascending=False).plot(
        kind='bar',
        xlabel='Рейтинг',
        ylabel= 'Процент проданных игр\nотносительного всех продаж в регионе',
        ax =axs[i],
        color=mcolors.XKCD_COLORS
    )
    axs[i].set_title(titles[i])
    i += 1

plt.show()
```

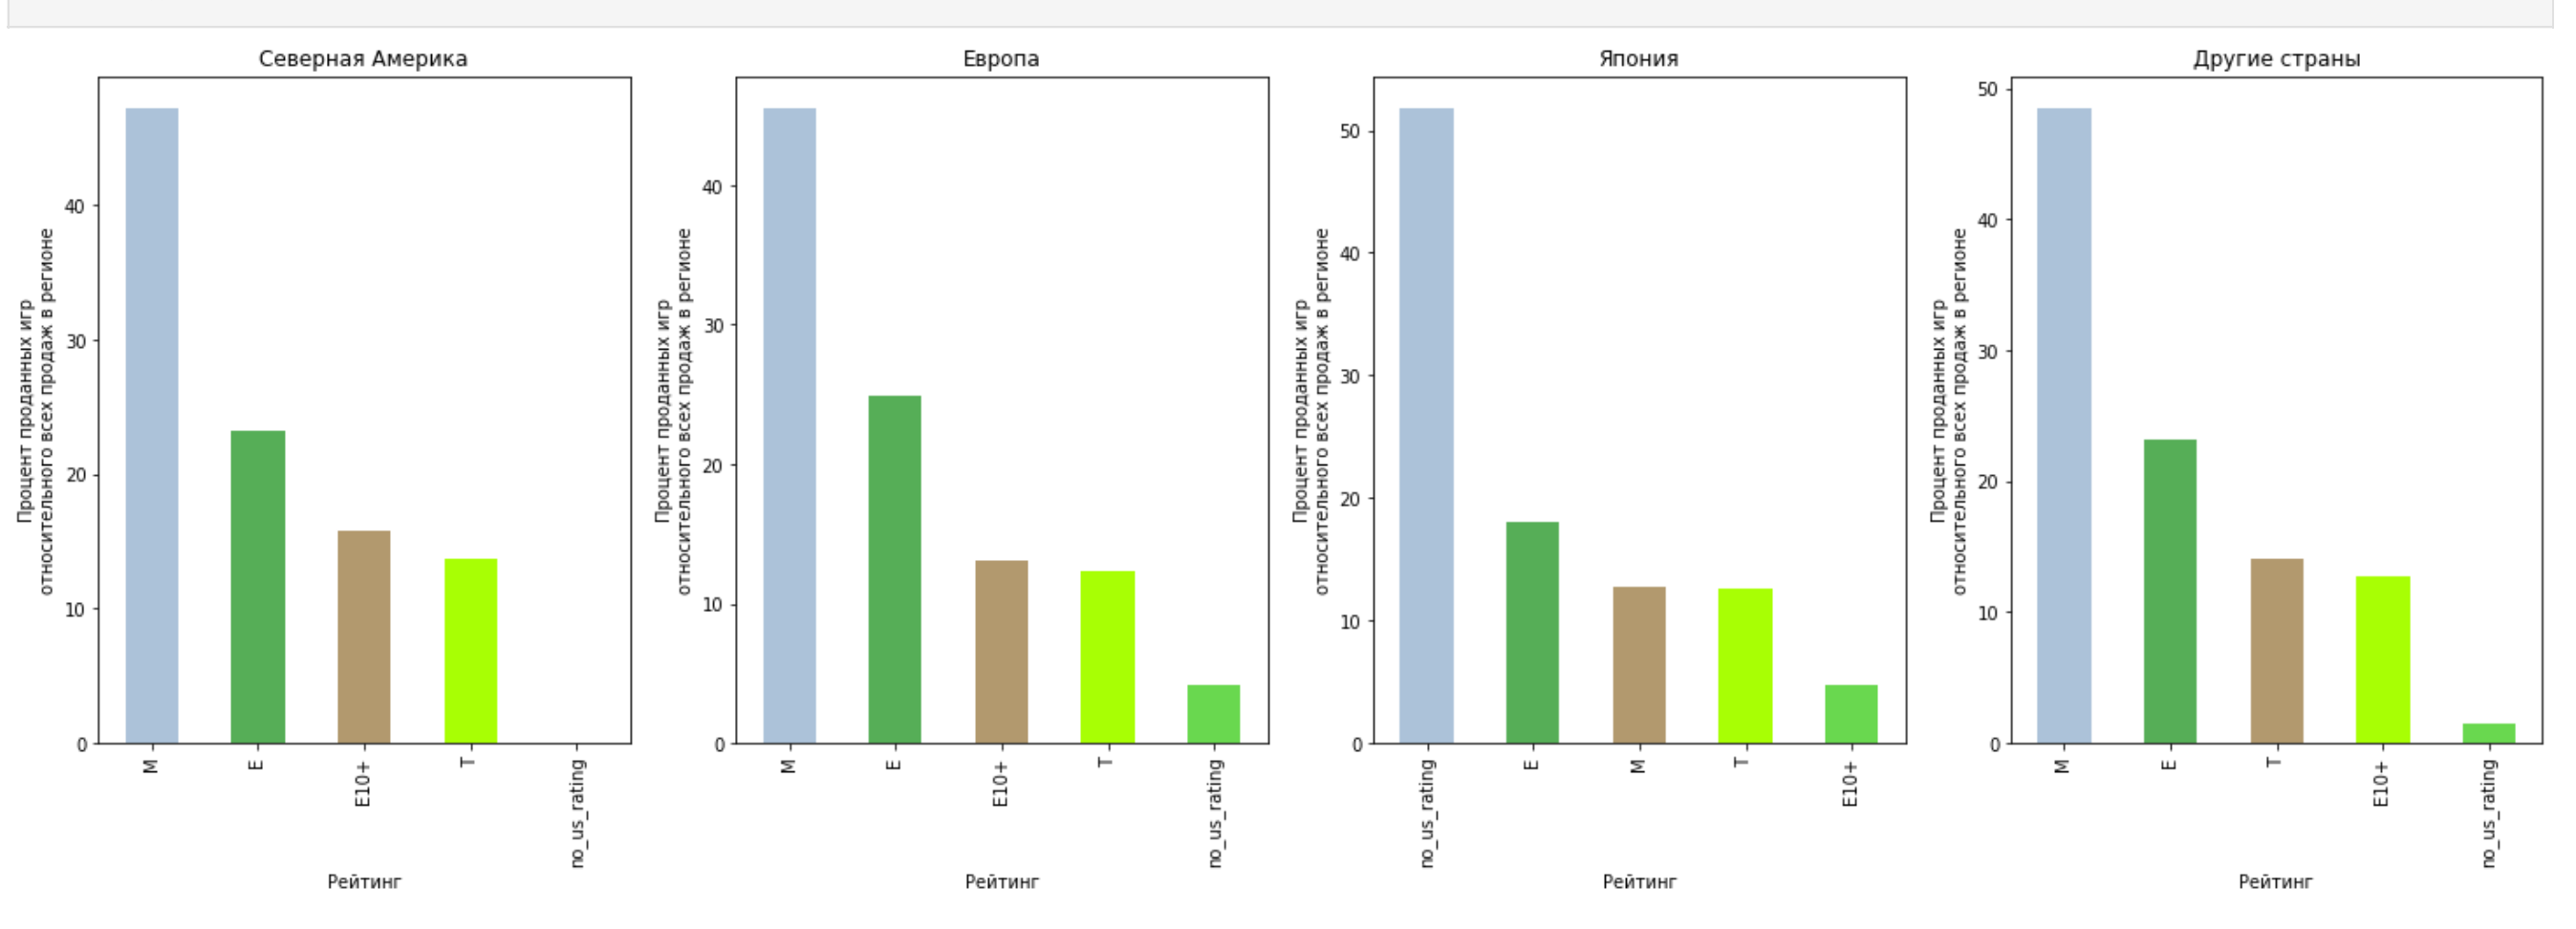

Как мы видим, больше всего продаж во всех регионах, кроме Японии, занимают игры с рейтингом **M - для взрослых**. Это логично, учитывая, что последние годы игры становятся все более вхрослым развлечением, на равне с сериалами и фильмами.

В Японии на первом месте игры, значение рейтинга для которых в имеющихся данных отсутствуют. Это связано с тем, что в Японии работает своя система возрастного рейтинга, а следовательно, все игры, выпускаемые исключительно для Японского региона, не имеют рейтинга от ESRB. В связи с этим, для анализа влияния рейтинга игр на их продажи в Японии необходимо отдельное исследование этого рынка.

На втором месте по продажам во всех регионах игры с рейтингом **E - для всех**.

Можно сделать вывод, что для большинства регионов, рейтинги **M** и **E** являются наиболее продаваемыми, несмотря на серьезные ограничения возраста играющих.

Вывод

До **1993** в год выпускалось довольно мало игр, не больше 50 наименований в год. Затем, до **2008** года был рост, когда количество выпущенных за год игр превысило 1400 выпущенных игр. После чего началось снижение, и с **2012** года в среднем выпускается порядка **500** игр в год. Кроме того, до **2000** года количество игр и их версий для различных платформ практически совпадало, после чего началось значительное увеличение выпуска одних и тех же игр для различных платформ. При этом, тенденция для обоих значений одинаковая.

Рассматривать продажи игр до **2002** года нерелевантно. Начиная с этого периода, соотношение количества игр совокупно для всех платформ и уникальных игр примерно одинаково.

Медианное значение жизненного цикла платформ составляет 8 лет. При этом, начиная с выхода Sony PlayStation, новые поколения платформ выходят в год, когда начинает снижаться количество выпущенных игр (в среднем, примерно на 2/3 от жизненного цикла предыдущего поколения).

Можно выделить 6 платформ с наибольшими продажами видеоигр за все время. Лидером, причем с большим отрывом (*до ближайшей платформы почти **300** млн копий*), является PS2. Затем, с разницей между продажами в **30 млн.**, XBox 360, PS3 и Wii. Nintendo DS и PlayStation замыкают список с **804** и **727** млн копий соответственно.
В целом, этими платформами можно описать весь современный промежуток игростроения. Характерно, что PS4, XBox One и WiiU имеют гораздо меньшее количество проданных копий, поскольку их старт начался относительно недавно, а следовательно, не все пользователи еще перешли на новое поколение.

Можно сделать вывод, что в 2017 году продажи игр на новое поколение приставок (*PS4, XBox One, WiiU*) выйдут на значения, близкие к пиковым. В связи с этим, логичным будет ***определить актуальным период с 2012 по 2016***. Таким образом, мы можем увидеть тенденции на платформах, являющихся самыми актуальными, при этом не испортив анализ более устаревшими данными.

Из всех представленных в акутальном преоиде платформ, самой постоянной является ПК - часть продаж, приходящаяся на эту платформу немного растет, хоть и не превышает **5%**. Так же мы видим, что продажи для XBox One росли с 2013 года, и только в 2016 немного упали (**до 20%**). Продажи игр на PlayStation 4 в 2016 году превысили **50%** от всех проданных игр.

В целом, по имеющимся данным можно сделать следующий вывод:

- в последние годы PlayStaton 4 лидирует по продажам, и учитывая год запуска, еще несколько лет продажи будут расти;
- продажи на XBox One так же растут, но медленнее, с падением на несколько процентов в 2016 году;
- продажи на Nintendo 3DS стабильно достигают 10-15%, возможен дальнейший рост, учитывая специфику устройств от Nintendo и популярности платформы в Японии;
- продажи на ПК не опускаются ниже 7% и график продаж ровный;
- продажи на устаревающие платформы (*XBox 360, PlayStation 3, Wii*) падают и в ближайшие годы прекратятся;
- WiiU превышает показателей предшественницы, продажи меньше 10% и тенденция к падению

Потенциально прибыльными платформами в 2017 году можно считать новое поколение известных приставок (**XBox One, PlayStation 4**), **ПК**, а так же нишевые устройчтва - **PS Vita, Nintendo 3DS**).

Анализ продаж по платформам позволяет сделать следующие выводы:

- у всех платформ медианное значение продаж находится ближе к первому квартилю
- у всех платформ есть выбросы, данные значения расположены выше верхней границы значений
- чем популярнее платформа, тем больше выбросов в значениях продаж
- чем популярнее плафторма, тем больше границы межквартильного размаха
- наибольшие медианные продажи у Xbox 360, первый и третий квартили так же имеют наибольшие значения
- PlayStation 3, PlayStation 4, XBox One, Wii и WiiU имеют схожие значения медианных продаж

Увеличение оценки как критиков, так и пользователей незначительно сказывается на продажах видеоигр, большинство продается на одном и том же уровне около 1 млн. копий. При этом, только у игр с отзывами критиков от 70 появляются игры с продажами, превышающими 5 млн проданных копий, и в целом, с ростом оценки распределение продаж становится шире. У распределения относительно отзывов пользователей такой картины не наблюдается. есть отдельные случаи больших продаж в независимости от оценок пользователей. Данные выводы справедливы как для всех платформ.

За актуальный период продавались игры в 12 жанрах. Самый частый жанр игр : **Action** (1040 игр). На втором месте ролевые игры (370). Третье место по количеству занимает жанр **Приключенческих игр** (302 наименования) . На четвертом месте - **Спортивные игры** (267 игры). Замыкает топ-5 жанров по количеству выпускаемых игр жанр **Шутеров** - 237 игры.

В различных регионах картина сильно различается.

- В **Северной Америке** самой популярной платформой за актуальный период является **XBox 360**, на него приходится более почти 25% процентов всех продаж в регионе.
- В **Европе** самой популярной является платформа **PlayStation 4**, на нее приходится почти 28% продаж. Д
- В **Японии** самой популярной является Nintendo 3DS - ~45% от всех продаж в регионе.
- В **остальных странах** самой популярной платформой является **PlayStation 4**, на нее приходится более 30% всех продаж.

В случае с жанрами, картина более однородная: во всех регионах за актуальный период доля **Экшн-игр** превышает 30%, а в случае с продажами в Европе, первышает практически 35%. При этом в Японии на первом месте жанр **Ролевых игр** (почти 38% всех продаж). *Это неудивительно, поскольку в данном регионе РПГ, а особенно поджанр jRPG (т.е. японские РПГ), очень популярен.*

Распределение продаж по жанрам в **Северной Америке и Европе** схоже и по остальным играм, кроме жанра, замыкающего топ-5: на пятом месте в случае Северной Америки находятся игры другого жанра, в Европе - гонки (~7%).

Как мы видим, больше всего продаж во всех регионах, кроме Японии, занимают игры с рейтингом **M - для взрослых**. Это логично, учитывая, что последние годы игры становятся все более вхрослым развлечением, на равне с сериалами и фильмами.

В Японии на первом месте игры, значение рейтинга для которых в имеющихся данных отсутствуют. Это связано с тем, что в Японии работает своя система возрастного рейтинга, а следовательно, все игры, выпускаемые исключительно для Японского региона, не имеют рейтинга от ESRB. В связи с этим, для анализа влияния рейтинга игр на их продажи в Японии необходимо отдельное исследование этого рынка.

На втором месте по продажам во всех регионах игры с рейтингом **E - для всех**.

Можно сделать вывод, что для большинства регионов, рейтинги **M** и **E** являются наиболее продаваемыми, несмотря на серьезные ограничения возраста играющих в случае с рейтингом **M**.

Проверка гипотез

Гипотеза 1. Средние пользовательские рейтинги платформ Xbox One и PC одинаковые

Для проверки этой гипотезы нам надо сравнить две независимые выборки. Следовательно, для проверки гипотезы мы выберем t-критерий Стьюдента для двух независимых выборок.

Нулевую гипотезу сформулируем так: *Средние пользовательские рейтинги для указанных платформ равны*

Альтернативная гипотеза: *Средние пользовательские рейтинги для указанных платформ не равны*

Пороговое значение `alpha` зададим равным 0.05

In [70]:

```
xone_user_score = actual_period_data.loc[
    actual_period_data['platform'] == 'XOne'
]['user_score'].dropna()

pc_user_score = actual_period_data.loc[
    actual_period_data['platform'] == 'PC'
]['user_score'].dropna()

results = st.ttest_ind(
    xone_user_score,
    pc_user_score,
    equal_var = True
)

results.pvalue
```

Out[70]:

```
0.5814663562474292
```

Как мы видим, полученное в результате значение `p` гораздо выше порогового, заданного нами.

Следовательно, данную гипотезу нельзя отвергнуть, и **средние пользовательские рейтинги платформ XBoxOne и PC равны**.

Для наглядности, сравним средние значения имеющихся выборок.

In [71]:

```
xone_mean = actual_period_data.loc[
    actual_period_data['platform'] == 'XOne'
]['user_score'].mean()

pc_mean = actual_period_data.loc[
    actual_period_data['platform'] == 'PC'
]['user_score'].mean()

print(f'Среднее значение рейтинга пользователя для XBox One: {xone_mean}')
print(f'Среднее значение рейтинга пользователя для ПК: {pc_mean}')
```

```
Среднее значение рейтинга пользователя для XBox One: 6.521428571428572
Среднее значение рейтинга пользователя для ПК: 6.435714285714286
```

Гипотеза 2. Средние пользовательские рейтинги жанров Action и Sports разные.

Для проверки этой гипотезы нам надо сравнить две независимые выборки. Следовательно, для проверки гипотезы мы выберем t-критерий Стьюдента для двух независимых выборок.

Нулевую гипотезу сформулируем так: *Средние пользовательские жанров Action и Sports равны*

Альтернативная гипотеза: *Средние пользовательские жанров Action и Sports не равны*

Пороговое значение `alpha` зададим равным 0.05

In [72]:
```
action_user_score = actual_period_data.loc[
    actual_period_data['genre'] == 'Action'
]['user_score'].dropna()

sports_user_score = actual_period_data.loc[
    actual_period_data['genre'] == 'Sports'
]['user_score'].dropna()

results = st.ttest_ind(
    action_user_score,
    sports_user_score,
    equal_var = True
)

results.pvalue
```

Out[72]:
```
1.912348990246777e-26
```

Значение p в разы меньше порогового значения, следовательно нулевая гипотеза отвергается.

Таким образом, **средние пользовательские рейтинги жанров Action и Sports разные**.

Для наглядности, сравним средние значения имеющихся выборок.

In [73]:
```
action_user_score = actual_period_data.loc[
    actual_period_data['genre'] == 'Action'
]['user_score'].mean()

sports_user_score = actual_period_data.loc[
    actual_period_data['genre'] == 'Sports'
]['user_score'].mean()

print(f'Среднее значение рейтинга пользователя для жанра Action: {action_user_score}')
print(f'Среднее значение рейтинга пользователя для жанра Sports: {sports_user_score}')
```

```
Среднее значение рейтинга пользователя для жанра Action: 6.831132075471698
Среднее значение рейтинга пользователя для жанра Sports: 5.455670103092784
```

Вывод

В результате статистической проверки гипотез с помощью t-критерия Стьюдента для назвисимых выборок, были получены следующие результаты:

- **средние пользовательские рейтинги платформ XBoxOne и PC равны**
- **средние пользовательские рейтинги жанров Action и Sports разные**

В обоих случаях пороговое значение `alpha` принималось равным 0,05.

Выводы по проекту

Исходные данные для проекта представляют собой общую информацию о видеоиграх. Имеется информация о **платформе**, **годе выпуска**, **жанре**, **продажах**, **оценках критиков и пользователей** и **возрастном рейтинге**.

В таблице **16715** строк. Имеется информация об играх с 1980 по 2016 год.

Цель проекта - проанализировать данные о международных продажах видеоигр для того, чтобы спланировать рекламную кампанию на следующий год.

Были поставлены следующие задачи:

- провести исследовательский анализ данных
- составить портер пользователя из каждого региона
- проверить гипотезы о рейтингах игр для различных платформ и рейтингах игр разных жанров

Предобработка данных

Все названия столбцов были приведены к формату `snake_case`.
Была выполнена проверка на наличие явных дубликатов, проверка показала, что такие данные отсутствуют. Неявные дубликаты были проверены по совпадениям одновременно названия, платформы и года релиза и были удалены. В таблицу был добавлен столбец с общими продажами игр по всем регионам.

Проверка пропусков показала, что в **6** столбцах присутствуют пропуски. Больше всего пропусков в столбце с оценками критиков (**8578**), чуть меньше пропусков в столбцах с оценками пользователей и возрастным рейтингом (**~6700**). По **1** пропуска в информации о названии видеоигры и жанра. Год выпуска не указан для **269** строк. Пропуски в названиях видеоигр и их жанрах оказались в одних строках, которые были удалены. Данное удаление не повлияет на дальнейший анализ, поскольку у этих видеоигр малые продажи, год выпуска у обеих игр 1993, а платформа, для которой выпускались данные игры, уже не выпускается и является устаревшей.

Пропуски в годе выпуска игр были заменены на год выпуска у тех же игр для других платформ, при этом была выполнена проверка, что все остальные платформы получили эту игру в один год. Таким образом, мы удостоверились, что возможная временная эксклюзивность игры для какой-либо платформы не повлияет на неверное заполнение пропусков. В итоге, в данном столбце осталось **158** пустых значений. ***Причиной пропусков в данном столбце могут говорить лишь о технической проблеме при получении данных, поскольку у всех игр, уже выпущенных и продающихся, известен год их выпуска***.

Пропуски в оценках критиков и пользователей не удалось заполнить, поскольку нет путей для точного заполнения данных значений. ***В данном случае причиной пропуска, помимо технической причины, является то, что данная игра вышла очень давно и на тот момент не существовало агрегаторов оценок критиков и пользователей***.

Пропуски в значениях рейтинга были заполнены на основании имеющихся данных о рейтинге игр для других платформ. Это помогло заполнить часть пропусков, но все равно осталось **6072** незаполненных значения. Кроме того, часть игр не выпускалась на рынках Северной Америки, что тоже привело к отсутствию рейтинга в таблице. Такие значения были заполнены соответственной заглушкой. ***В этом случае причиной прпоуска, помимо технической, вяляется то, что самая организация, выдающая рейтинг, была основана лишь в 1993 году, то есть все игры до этого не имели какой-либо унифицированной шкалы по возрастному рейтингу, а так же то, что игра не выпускалась на рынках Северной Америки, а следовательно, ей не присваивался рейтинг ESRB***.

После обработки пропусков некоторые столбцы были приведены к новым типам для облегчения дальнейшего анализа: тип значений в столбце **год выпуска** был заменен на целочисленный, а значения в столбце с **оценками пользователей** был заменен на вещественный тип. При этом, в столбце с оценками пользователей присутствовали занчения **tbd**, что означает недостаточное количество имеющихся оценок для подсчета среднего. В этом случае значения были заменены на `NaN`.

Исследовательский анализ данных

До **1993** в год выпускалось довольно мало игр, не больше 50 наименований в год. Затем, до **2008** года был рост, когда количество выпущенных за год игр превысило 1400 выпущенных игр. После чего началось снижение, и с **2012** года в среднем выпускается порядка **500** игр в год. Кроме того, до **2000** года количество игр и их версий для различных платформ практически совпадало, после чего началось значительное увеличение выпуска одних и тех же игр для различных платформ. При этом, тенденция для обоих значений одинаковая.

Рассматривать продажи игр до **2002** года нерелевантно. Начиная с этого периода, соотношение количества игр совокупно для всех платформ и уникальных игр примерно одинаково.

Медианное значение жизненного цикла платформ составляет 8 лет. При этом, начиная с выхода Sony PlayStation, новые поколения платформ выходят в год, когда начинает снижаться количество выпущенных игр (в среднем, примерно на 2/3 от жизненного цикла предыдущего поколения).

Можно выделить 6 платформ с наибольшими продажами видеоигр за все время. Лидером, причем с большим отрывом (*до ближайшей платформы почти **300** млн копий*), является PS2. Затем, с разницей между продажами в **30 млн.**, XBox 360, PS3 и Wii. Nintendo DS и PlayStation замыкают список с **804** и **727** млн копий соответственно.
В целом, этими платформами можно описать весь современный промежуток игростроения. Характерно, что PS4, XBox One и WiiU имеют гораздо меньшее количество проданных копий, поскольку их старт начался относительно недавно, а следовательно, не все пользователи еще перешли на новое поколение.

Можно сделать вывод, что в 2017 году продажи игр на новое поколение приставок (*PS4, XBox One, WiiU*) выйдут на значения, близкие к пиковым. В связи с этим, логичным будет ***определить актуальным период с 2012 по 2016***. Таким образом, мы можем увидеть тенденции на платформах, являющихся самыми актуальными, при этом не испортив анализ более устаревшими данными.

Из всех представленных в акутальном преоиде платформ, самой постоянной является ПК - часть продаж, приходящаяся на эту платформу немного растет, хоть и не превышает **5%**. Так же мы видим, что продажи для XBox One росли с 2013 года, и только в 2016 немного упали (**до 20%**). Продажи игр на PlayStation 4 в 2016 году превысили **50%** от всех проданных игр.

В целом, по имеющимся данным можно сделать следующий вывод:

- в последние годы PlayStaton 4 лидирует по продажам, и учитывая год запуска, еще несколько лет продажи будут расти;
- продажи на XBox One так же растут, но медленнее, с падением на несколько процентов в 2016 году;
- продажи на Nintendo 3DS стабильно достигают 10-15%, возможен дальнейший рост, учитывая специфику устройств от Nintendo и популярности платформы в Японии;
- продажи на ПК не опускаются ниже 7% и график продаж ровный;
- продажи на устаревающие платформы (*XBox 360, PlayStation 3, Wii*) падают и в ближайшие годы прекратятся;
- WiiU превышает показателей предшественницы, продажи меньше 10% и тенденция к падению

Потенциально прибыльными платформами в 2017 году можно считать новое поколение известных приставок (**XBox One, PlayStation 4**), **ПК**, а так же нишевые устройчтва - **PS Vita, Nintendo 3DS**).

Анализ продаж по платформам позволяет сделать следующие выводы:

- у всех платформ медианное значение продаж находится ближе к первому квартилю
- у всех платформ есть выбросы, данные значения расположены выше верхней границы значений
- чем популярнее платформа, тем больше выбросов в значениях продаж
- чем популярнее плафторма, тем больше границы межквартильного размаха
- наибольшие медианные продажи у Xbox 360, первый и третий квартили так же имеют наибольшие значения
- PlayStation 3, PlayStation 4, XBox One, Wii и WiiU имеют схожие значения медианных продаж

Увеличение оценки как критиков, так и пользователей незначительно сказывается на продажах видеоигр, большинство продается на одном и том же уровне около 1 млн. копий. При этом, только у игр с отзывами критиков от 70 появляются игры с продажами, превышающими 5 млн проданных копий, и в целом, с ростом оценки распределение продаж становится шире. Оценки критиков влияют сильнее, чем оценки пользователей, но это влияние достаточно мало. Только среди игр на японские платформы (Nintendo 3DS и Nintendo WiiU) коэффициент корреляции продаж игр с отзывами пользователей выше. При этом, во всех случаях, он не превышает 0.5, так что доводов говорить о сильной взаимосвязи исходя из этих графиков нельзя.

За актуальный период продавались игры в 12 жанрах. Самый частый жанр игр : **Action** (1040 игр). На втором месте ролевые игры (370). Третье место по количеству занимает жанр **Приключенческих игр** (302 наименования) . На четвертом месте - **Спортивные игры** (267 игры). Замыкает топ-5 жанров по количеству выпускаемых игр жанр **Шутеров** - 237 игры.

В различных регионах картина сильно различается.

- В **Северной Америке** самой популярной платформой за актуальный период является **XBox 360**, на него приходится более почти 25% процентов всех продаж в регионе.
- В **Европе** самой популярной является платформа **PlayStation 4**, на нее приходится почти 28% продаж. Д
- В **Японии** самой популярной является Nintendo 3DS - ~45% от всех продаж в регионе.
- В **остальных странах** самой популярной платформой является **PlayStation 4**, на нее приходится более 30% всех продаж.

В случае с жанрами, картина более однородная: во всех регионах за актуальный период доля **Экшн-игр** превышает 30%, а в случае с продажами в Европе, первышает практически 35%. При этом в Японии на первом месте жанр **Ролевых игр** (почти 38% всех продаж). *Это неудивительно, поскольку в данном регионе РПГ, а особенно поджанр jRPG (т.е. японские РПГ), очень популярен*.

Распределение продаж по жанрам в **Северной Америке и Европе** схоже и по остальным играм, кроме жанра, замыкающего топ-5: на пятом месте в случае Северной Америки находятся игры другого жанра, в Европе - гонки (~7%).

Как мы видим, больше всего продаж во всех регионах, кроме Японии, занимают игры с рейтингом **M - для взрослых**. Это логично, учитывая, что последние годы игры становятся все более вхрослым развлечением, на равне с сериалами и фильмами.

В Японии на первом месте игры, значение рейтинга для которых в имеющихся данных отсутствуют. Это связано с тем, что в Японии работает своя система возрастного рейтинга, а следовательно, все игры, выпускаемые исключительно для Японского региона, не имеют рейтинга от ESRB. В связи с этим, для анализа влияния рейтинга игр на их продажи в Японии необходимо отдельное исследование этого рынка.

На втором месте по продажам во всех регионах игры с рейтингом **E - для всех**.

Можно сделать вывод, что для большинства регионов, рейтинги **M** и **E** являются наиболее продаваемыми, несмотря на серьезные ограничения возраста играющих в случае с рейтингом **M**.

Проверка гипотез В результате статистической проверки гипотез с помощью t-критерия Стьюдента для назвисимых выборок, были получены следующие результаты:

- **средние пользовательские рейтинги платформ XBoxOne и PC равны**
- **средние пользовательские рейтинги жанров Action и Sports разные**

В обоих случаях пороговое значение `alpha` принималось равным 0,05.

По итогам проведенного анализа можно сказать следующее:

1. Самыми популярными платформами являются:
    - Для Северной Америки:
        - XBox 360
        - PS4
    - Для Европы:
        - PS4
        - PS3
    - Для Японии:
        - Nintendo 3DS
        - PS3
    - Для других стран:
        - PS4
        - PS3 ***С учетом того факта, что жизненный цикл самых современных платформ приближается к середине, в 2017 году можно прогнозировать пиковые продажи игр для них. Поэтому, рекомендуется выбрать PS4 и XBox One как наиболее прибыльные платформы для рекламной кампании 2017 года по всему миру и Nintendo 3DS исключительно для Японии.***
2. Самыми популярными жанрами являются:
    - Для Северной Америки:
        - Action
        - Shooter
    - Для Европы:
        - Action
        - Shooter
    - Для Японии:
        - Ролевые игры
        - Action
    - Для других стран:
        - Action
        - Shooter ***С учетом вышеизложенного, самыми востребованными являются игры в жанрах Action и Shooter, кроме Японии, где привлекательны в первую очередь ролевые игры. Рекомендуется потратить рекламный бюджет на продвижение игр в жанрах Action и Shooter по всему миру, а также ролевые игры для японского рынка***.
3. ***В плане рейтинга, по всему миру, кроме Японии, следует рекламировать игры рейтинга M и E. Японский рынок требует дополнительного изучения в связи с собственной системой возрастных ограничений и большим количеством игр, нацеленных исключительно на этот рынок***.
4. ***Оценки пользователей и критиков не имеют большого влияния на продажи, но, несмотря на это, рекомендуется уделять внимание играм с более высокими оценками критиков***.